Escuela Tecnológica Instituto Técnico Central
(ETITC)

Facultad de Sistemas
Ingeniería de Sistemas

Sistema predictivo basado en Machine Learning para el pronóstico neurológico post-paro cardíaco: una línea base enfocada en la extracción de características de señales EEG

Trabajo de grado presentado como requisito para optar al título de
Ingeniero de Sistemas

Manuel Felipe Pacheco Gutiérrez
CC 1.007.103.302

Prof. Juan David Leal Campuzano
Asesor de Trabajo de Grado

Grupo de Investigación VIRTUS

Bogotá D.C.
2026

Agradecimientos

Primeramente, a Dios, por haber estado conmigo en todo momento.

A mis consultores, Sebastián Yepes y Juan Leal, por la oportunidad de presentar este trabajo y por retarme a hacerlo de la mejor manera posible. Sus comentarios me exigieron revisar cada decisión hasta poder sostenerla, y este documento es mejor gracias a ellos.

A mi familia, por su ayuda y por darme la fuerza para seguir siempre hacia adelante.

Resumen

Tras un paro cardíaco, cerca del 80 % de los pacientes reanimados llega en coma a la unidad de cuidados intensivos, y alrededor de la mitad de quienes sobreviven sigue sin despertar 72 horas después; el pronóstico neurológico que se emite en los primeros días influye en la decisión de mantener o retirar el soporte vital, una decisión que debe apoyarse en una evaluación multimodal en la que el EEG es solo una de las pruebas. El electroencefalograma (EEG) aporta información pronóstica, pero su interpretación visual varía entre evaluadores (Westhall et al., 2015) y depende de especialistas. Este trabajo estableció una línea base para predecir, a partir del EEG registrado entre las 24 y las 72 horas posteriores a la reanimación, si el paciente tendrá un desenlace neurológico favorable, definido como un nivel 1 o 2 en la escala CPC (buena función cerebral o discapacidad moderada) y tomado como el mejor nivel registrado entre los tres y los seis meses posteriores al paro, mediante un modelo de aprendizaje de máquina clásico, y caracterizó el costo computacional del proceso completo. Siguiendo la metodología CRISP-DM, se procesaron registros de la base pública I-CARE: la señal se filtró, re-referenció y segmentó en épocas de 10 segundos, y se extrajeron 20 características que no dependen de la escala de la señal. Se evaluaron cuatro familias de algoritmos con validación cruzada anidada, agrupada por paciente, sobre 17 pacientes de desarrollo, y el modelo final se probó una sola vez sobre 14 pacientes de una partición retenida de la misma base, apartada antes de examinar ninguna señal. De los 35 pacientes seleccionados por su etiqueta de desenlace, cuatro se excluyeron por no tener EEG dentro de la ventana. El AUC fue de 0,556 (IC 95 %: 0,242-0,848) en validación cruzada y de 0,708 (IC 95 %: 0,375-0,959) en el conjunto retenido. Ninguna de las dos pruebas de permutación mostró evidencia estadísticamente significativa de una discriminación superior al azar ($p = 0{,}178$ y $p = 0{,}114$). Ajustar el clasificador toma 0,15 segundos, y producir el pronóstico de un paciente nuevo desde su EEG crudo, sumando lectura, preprocesamiento, extracción de características e inferencia, cerca de un minuto, en un portátil de seis núcleos sin tarjeta gráfica dedicada. El aporte es una línea base reproducible, con cada decisión

declarada. Con este tamaño de muestra, las estimaciones son demasiado inciertas para establecer si el modelo tiene capacidad predictiva, y el trabajo deja medido el punto de partida para estudios con más pacientes.

Palabras clave: aprendizaje de máquina, electroencefalograma, pronóstico neurológico, paro cardíaco, procesamiento de señales.

Abstract

After cardiac arrest, about 80 % of resuscitated patients arrive comatose at the intensive care unit, and around half of those who survive remain unresponsive 72 hours later; the neurological prognosis given in the first days shapes the decision to continue or withdraw life support, a decision that must rest on a multimodal assessment in which the EEG is only one of the tests. The electroencephalogram (EEG) carries prognostic information, but its visual interpretation varies between raters (Westhall et al., 2015) and depends on specialists. This work established a baseline for predicting, from the EEG recorded between 24 and 72 hours after resuscitation, whether the patient will have a favourable neurological outcome, defined as level 1 or 2 on the CPC scale (good cerebral performance or moderate disability) and taken as the best level recorded between three and six months after the arrest, using a classical machine learning model, and it characterized the computational cost of the whole process. Following the CRISP-DM methodology, recordings from the public I-CARE database were processed: the signal was filtered, re-referenced and segmented into 10-second epochs, and 20 features that do not depend on the signal scale were extracted. Four families of algorithms were evaluated with nested cross-validation, grouped by patient, on 17 development patients, and the final model was tested only once on 14 patients from a held-out partition of the same database, set aside before any signal was examined. Of the 35 patients selected by their outcome label, four were excluded for having no EEG within the window. The AUC was 0.556 (95 % CI: 0.242-0.848) in cross-validation and 0.708 (95 % CI: 0.375-0.959) on the held-out set. Neither of the two permutation tests showed statistically significant evidence of discrimination better than chance ($p = 0.178$ and $p = 0.114$). Fitting the classifier takes 0.15 seconds, and producing the prognosis of a new patient from their raw EEG, including reading, preprocessing, feature extraction and inference, takes about one minute on a six-core laptop without a dedicated graphics card. The contribution is a reproducible baseline, with every decision declared. With this sample size the

estimates are too uncertain to establish whether the model has predictive ability, and the work sets a measured starting point for studies with more patients.

Keywords: machine learning, electroencephalogram, neurological prognosis, cardiac arrest, signal processing.

Tabla de contenido

Agradecimientos I

Resumen II

Abstract IV

1. Introducción 1

2. Justificación 3

3. Planteamiento del Problema 6

3.1. Descripción del Problema 6

3.2. Formulación del Problema 7

3.3. Hipótesis de Investigación 7

4. Objetivos 9

4.1. Objetivo General 9

4.2. Objetivos Específicos 9

5. Marco Teórico 11

5.1. Fundamentos Clínicos y Neurofisiológicos 11

5.1.1. Coma Post-Paro Cardíaco 11

5.1.2. El Electroencefalograma (EEG) en Cuidados Intensivos 12

5.2. Procesamiento de Señales y Extracción de Características 13

5.2.1. Naturaleza de la Señal EEG y Artefactos 13

5.2.2. Conceptos Básicos para la Limpieza de la Señal 14

5.2.3. Electroencefalografía Cuantitativa (QEEG) 16

5.2.4. Características Específicas: Dominio de Frecuencia y Complejidad 18
5.2.5. Las Características Empleadas: Cinco Familias 20
5.2.6. Ingeniería de Características 22
5.3. Aprendizaje de Máquina (Machine Learning) en Pronóstico Clínico 23
5.3.1. Paradigma Clásico vs. Aprendizaje Profundo 23
5.3.2. Modelos Supervisados de Clasificación 24
5.3.3. Métricas de Evaluación de Rendimiento y Validación 26

6. Metodología **31**
6.1. Selección y Justificación de la Metodología 31
6.2. Fases de Desarrollo del Proyecto 32
6.2.1. Comprensión del Entorno y los Datos 32
6.2.2. Preprocesamiento y Limpieza de Señales 47
6.2.3. Ingeniería de Características (Feature Engineering) 55
6.2.4. Modelado Computacional 56
6.2.5. Validación y Evaluación 59

7. Resultados **63**
7.1. Resultados del Preprocesamiento de Señales 63
7.2. Resultados de la Extracción de Características 63
7.3. Resultados del Modelado y la Validación Cruzada 67
7.4. Resultados de la Evaluación Held-Out 69
7.5. Costo Computacional 71

8. Discusión **74**
8.1. Interpretación de los Resultados Principales 74
8.2. Comparación con la Literatura 77
8.3. Limitaciones del Estudio 79

9. Conclusiones **82**

9.1. Conclusiones Generales 82

9.2. Trabajo Futuro 84

Referencias **86**

Lista de figuras

5.1. El EEG en el flujo de pronóstico neurológico de la UCI 13
5.2. Frontera de decisión de los cuatro algoritmos evaluados 26

6.1. La escala CPC y la línea de corte del desenlace binario 33
6.2. Anatomía de un segmento y organización de los datos 34
6.3. Mapa de la cohorte ordenada por identificador 38
6.4. Selección de los pacientes empleados 41
6.5. Distribución de la escala CPC por conjunto 43
6.6. Caracterización clínica de la cohorte 44
6.7. Hora máxima de registro por paciente 45
6.8. Cobertura de la ventana de 24 a 72 horas por paciente 47
6.9. Los 19 canales utilizados en el sistema 10-20 48
6.10. El embudo de señal de un paciente 52
6.11. Recorrido completo de la señal, del EEG crudo al pronóstico 54

7.1. Distribución de las 20 características por paciente y por clase 66
7.2. Cada resultado frente al azar de su propio protocolo 69
7.3. Probabilidad asignada a cada paciente 71

Lista de tablas

5.1. Variables de EEG cuantitativo y su significado clínico 18

6.1. Los 35 pacientes descargados y su reparto entre conjuntos 39

6.2. Las 20 características extraídas de cada época 55

7.1. Resultado del preprocesamiento por paciente 64

7.2. Desempeño en la validación cruzada anidada 68

7.3. Desempeño sobre el conjunto de prueba retenido 69

7.4. Costo computacional medido 72

Capítulo 1

Introducción

Los avances en inteligencia artificial han abierto nuevas posibilidades para apoyar el trabajo de los profesionales de la salud, especialmente en situaciones donde el tiempo y la precisión son fundamentales para salvar vidas. Este trabajo de grado aborda uno de esos problemas: el pronóstico neurológico de pacientes que permanecen en estado de coma tras un paro cardíaco, mediante la aplicación de herramientas matemáticas y computacionales al análisis de las señales eléctricas del cerebro (electroencefalograma, o EEG).

El paro cardíaco es una de las emergencias médicas más graves a nivel mundial. Aunque las tasas de supervivencia han mejorado en los últimos años, cerca del 80 % de los pacientes que logran recuperar el pulso quedan en estado de coma debido a que el cerebro estuvo un tiempo sin recibir oxígeno, y alrededor de la mitad de quienes sobreviven siguen sin despertar después de tres días (Benghanem et al., 2022). En estos casos, predecir si el paciente podrá recuperar su función neurológica se convierte en una decisión médica y ética muy delicada, ya que de ella se sigue, por ejemplo, si se continúa o se retira el soporte vital. Tradicionalmente, esta predicción recae en gran parte sobre la experiencia visual de un neurofisiólogo que interpreta el EEG del paciente, una interpretación que varía entre evaluadores (Westhall et al., 2015) y queda sujeta a la disponibilidad de especialistas, que suelen ser escasos en las unidades de cuidados intensivos (Herman et al., 2015).

Para reducir esta dependencia del criterio humano, la investigación reciente ha explorado el uso de modelos de aprendizaje profundo (Deep Learning), capaces de aprender directamente de la señal de EEG sin que un humano indique qué buscar, a cambio de requerir grandes volúmenes de datos y recursos computacionales considerables (Ezugwu et al., 2025). Antes de recurrir a esa complejidad, sin embargo, hace falta una referencia: sin saber hasta dónde llega un enfoque más simple, no es posible saber cuánto aporta uno más complejo.

Este trabajo de grado construye esa referencia mediante un modelo de aprendizaje de máquina clásico (es decir, algoritmos más simples y menos costosos computacionalmente que el aprendizaje profundo), entrenado a partir de características extraídas de las señales de EEG, como su nivel de entropía o su distribución de frecuencias, en lugar de usar la señal cruda directamente. Se evalúan cuatro familias de algoritmos clásicos, descritas en el Capítulo 5. La investigación utiliza la base de datos I-CARE (International Cardiac Arrest Research Consortium), que reúne registros de EEG de 1020 pacientes en coma tras un paro cardíaco, 607 de ellos de acceso público (Amorim et al., 2023). Es importante aclarar desde el principio que este trabajo no emplea la base de datos completa: se trata de una primera versión, construida sobre un grupo reducido de pacientes, cuyo propósito es dejar establecido y documentado todo el proceso, desde la señal cruda hasta la evaluación del modelo. El proyecto está vinculado al Grupo de Investigación VIRTUS de la Escuela Tecnológica Instituto Técnico Central (ETITC), y su aporte es precisamente ese: una línea base construida con un criterio de validación estricto, que deja medido qué se puede y qué no se puede afirmar con esta cantidad de pacientes, y contra la cual deberá medirse cualquier modelo posterior del grupo, ya sea con más pacientes o con arquitecturas de aprendizaje profundo: un modelo más complejo solo se justifica si supera esta referencia.

El presente documento está organizado de la siguiente manera: el Capítulo 2 presenta la justificación del proyecto; el Capítulo 3 plantea el problema de investigación y la pregunta que guía este trabajo; el Capítulo 4 describe los objetivos general y específicos; el Capítulo 5 desarrolla el marco teórico necesario para comprender el EEG, el procesamiento de señales y los modelos de aprendizaje de máquina utilizados; el Capítulo 6 detalla la metodología seguida durante el desarrollo del proyecto; los Capítulos 7 y 8 presentan los resultados obtenidos y su discusión; y finalmente, el Capítulo 9 recoge las conclusiones y el trabajo futuro.

Capítulo 2

Justificación

El desarrollo de este proyecto se fundamenta en tres razones principales: la optimización de recursos computacionales, la falta de interpretabilidad de los modelos de inteligencia artificial en entornos clínicos, y la necesidad metodológica de contar con una línea base contra la cual puedan compararse, en trabajos posteriores, modelos más complejos.

En primer lugar, desde una perspectiva de ingeniería de sistemas, la tendencia actual en el aprendizaje automático aplicado a la salud es el uso de arquitecturas de aprendizaje profundo cada vez más grandes y costosas (Ezugwu et al., 2025). Si bien estos enfoques pueden alcanzar altos niveles de precisión, requieren tarjetas gráficas especializadas y tiempos de entrenamiento elevados, recursos que no siempre están disponibles en todos los centros hospitalarios, especialmente en países en vía de desarrollo. Por esta razón, explorar algoritmos de aprendizaje de máquina clásico, como los bosques aleatorios, las máquinas de vectores de soporte o la potenciación del gradiente, a partir de características extraídas de la señal de EEG representa un aporte importante para facilitar el acceso a herramientas de predicción eficientes y de bajo costo computacional.

Este costo no es solo un problema técnico. Se ha señalado que la escalada de recursos computacionales restringe la investigación en inteligencia artificial a las instituciones con mayor financiación (Schwartz et al., 2020), una barrera que se traslada a los centros hospitalarios con menos recursos. El beneficio de un enfoque clásico tampoco se limita al entrenamiento: también se refleja en la inferencia, es decir, en el momento de evaluar a un paciente nuevo, y en el despliegue, ya que un modelo que corre en un computador de uso común es más fácil de instalar y mantener dentro de un hospital que uno que exige hardware dedicado junto a la cama del paciente. Este trabajo caracteriza ese costo como una propiedad medida del sistema construido, y no como una comparación con modelos que no se entrenaron aquí (ver Sección 7.5).

En segundo lugar, la adopción de la inteligencia artificial en la práctica médica se ve frecuentemente limitada por el problema conocido como «caja negra»: la dificultad de explicar con claridad por qué un modelo llega a una conclusión específica, algo muy común en las redes neuronales profundas. Validar y auditar el desempeño de un modelo antes de confiar en él es un paso indispensable en cualquier proceso de ciencia de datos aplicado a la salud (Maleki et al., 2020).

En este trabajo esa transparencia se apoya, sobre todo, en la información que se le entrega al modelo. Las variables que entran son cantidades con un nombre concreto y un significado propio, calculadas sobre canales identificados del montaje: cuánta energía hay en cada banda de frecuencia, qué tan irregular es la señal y varios descriptores de su forma en el tiempo (Saeidi et al., 2021). Cualquiera de ellas puede revisarse, graficarse y discutirse con el personal médico, porque corresponde a algo que se puede señalar sobre el registro del paciente. Un modelo de aprendizaje profundo, en cambio, recibe la señal cruda y construye por su cuenta variables internas que no tienen un nombre clínico, lo que dificulta someterlas a revisión. En decisiones de alto riesgo se ha argumentado que conviene emplear modelos que puedan entenderse desde el principio, en lugar de construir explicaciones aproximadas sobre un modelo ya entrenado (Rudin, 2019). Esta primera versión deja esas variables identificadas y medidas; medir cuánto pesa cada una en la predicción, e incorporar medidas de conectividad entre canales como las empleadas en la literatura sobre coma postanóxico (Carrasco-Gómez et al., 2021), queda planteado como trabajo futuro.

Finalmente, a nivel metodológico e institucional, este trabajo se justifica como un componente importante dentro del macroproyecto de investigación del Grupo VIRTUS de la Escuela Tecnológica Instituto Técnico Central (ETITC), orientado a explorar modelos de predicción de pronóstico neurológico a partir de EEG en pacientes en coma tras un paro cardíaco. En ciencia de datos, no es posible afirmar que un modelo complejo es superior sin antes compararlo contra un modelo más simple. Este proyecto busca proveer el término simple de esa comparación, utilizando la base de datos I-CARE (International Cardiac Arrest Research Consortium) (Amorim et al., 2023). El aporte concreto al macroproyecto del Grupo VIRTUS es dejar establecida esa primera medida de referencia: un procedimiento documentado de principio a fin, que abarca el preprocesamiento de la

señal, la extracción de características, la validación y la evaluación, junto con un resultado numérico obtenido bajo un esquema de validación estricto. De esta forma el modelo clásico queda como línea base para las investigaciones siguientes del grupo, que al incorporar más pacientes o arquitecturas más complejas podrán medirse contra una referencia propia en lugar de partir de cero.

Capítulo 3

Planteamiento del Problema

3.1 Descripción del Problema

En las Unidades de Cuidados Intensivos (UCI), la monitorización continua mediante electroencefalograma se ha consolidado como una herramienta fundamental para evaluar la función cerebral y predecir el pronóstico de pacientes en estado de coma tras un paro cardíaco por falta de oxígeno. Sin embargo, la recolección continua de estas señales genera un volumen considerable de datos crudos. Para dimensionarlo conviene tomar un ejemplo concreto, ya que la frecuencia de muestreo varía de un registro a otro: un paciente registrado a 500 Hz sobre 19 canales produce, en tres días de monitoreo continuo, cerca de 5 GB de señal, que además debe revisarse manualmente. Este proceso queda sujeto a la disponibilidad de neurofisiólogos especialistas, que suelen ser escasos, lo cual genera cuellos de botella que pueden retrasar decisiones médicas importantes (Herman et al., 2015).

Ante este desafío, la comunidad científica ha explorado el uso de inteligencia artificial. Parte de la investigación reciente se ha enfocado en la construcción de modelos de aprendizaje profundo capaces de aprender representaciones complejas directamente de la señal de electroencefalograma. Sin embargo, desde la perspectiva de la ingeniería de sistemas, la aplicación de estos modelos plantea un problema secundario: un costo computacional elevado (Ezugwu et al., 2025). Conviene distinguir dos etapas, porque no cuestan lo mismo. La primera es el entrenamiento, que es donde se concentra el gasto: requiere tarjetas gráficas especializadas y tiempos prolongados, y debe repetirse cada vez que el modelo se reajusta. La segunda es la inferencia, es decir, usar un modelo ya entrenado para evaluar a un paciente nuevo, que resulta mucho más barata, aunque en los modelos profundos suele seguir necesitando hardware dedicado si se quiere sostener un monitoreo continuo junto al paciente. Este trabajo se ocupa de ambas.

El problema central radica en que actualmente no se sabe con certeza si esa alta complejidad y costo son estrictamente necesarios para una tarea de clasificación binaria: predecir si el pronóstico neurológico del paciente será favorable o desfavorable. La literatura muestra que la señal de electroencefalograma en pacientes en coma posee características identificables en el dominio del tiempo y la frecuencia (Saeidi et al., 2021). Por lo tanto, existe un vacío de conocimiento sobre cuál es el rendimiento real de algoritmos de aprendizaje de máquina clásico cuando se alimentan con características bien definidas de la señal, y si estos enfoques más simples podrían ser una alternativa técnica viable y menos costosa. Este vacío no se plantea de forma general, sino acotado al problema concreto que aborda este trabajo: el pronóstico neurológico de pacientes en coma tras un paro cardíaco, sobre los registros del conjunto de datos I-CARE y evaluado con un criterio de validación que separe a los pacientes entre entrenamiento y prueba.

3.2 Formulación del Problema

Con base en lo expuesto, la presente investigación plantea la siguiente pregunta:

> ¿En qué medida un modelo de aprendizaje de máquina clásico, construido a partir de la evaluación de cuatro familias de algoritmos y basado en la extracción explícita de características temporales y espectrales del electroencefalograma, permite predecir el pronóstico neurológico de pacientes en coma tras un paro cardíaco a partir de los registros del conjunto de datos I-CARE, evaluado mediante el área bajo la curva ROC a nivel de paciente?

3.3 Hipótesis de Investigación

El preprocesamiento de la señal de electroencefalograma y la posterior extracción explícita de características, como la densidad espectral de potencia y la entropía, permiten que un modelo de aprendizaje de máquina clásico distinga entre los pacientes que alcanzan un desenlace neurológico favorable y los que no, con un área bajo la curva ROC a nivel de paciente que cumpla dos

condiciones a la vez: que su diferencia con el azar propio del protocolo de validación empleado sea estadísticamente significativa ($p < 0{,}05$), y que alcance al menos 0,70, umbral que se adopta como criterio operativo para contrastar la hipótesis, tomado de la escala con que la literatura gradúa la discriminación de una prueba (Mandrekar, 2010). Cumplirlo no implicaría utilidad clínica: la significación indica si hay discriminación, el AUC cuánta, y la aplicabilidad clínica exigiría además validación externa y calibración, que esta línea base no aborda. Se plantea además que su costo computacional permita entrenarlo en un computador de uso común, sin necesidad de una tarjeta gráfica especializada.

Capítulo 4

Objetivos

4.1 Objetivo General

Establecer una línea base de rendimiento predictivo y de costo computacional para el pronóstico neurológico de pacientes en coma tras un paro cardíaco, que sirva como referencia para trabajos posteriores, mediante un modelo de predicción binaria basado en algoritmos de aprendizaje de máquina clásico y construido a partir de los registros de electroencefalograma de la base de datos I-CARE.

4.2 Objetivos Específicos

1. Implementar un flujo de preprocesamiento de las señales de electroencefalograma que permita la mitigación de artefactos, el filtrado de frecuencias no fisiológicas y la segmentación de la señal cruda proveniente de entornos de cuidados intensivos.
2. Extraer características neurofisiológicas cuantitativas en los dominios del tiempo, la frecuencia y la complejidad de la señal, conformando vectores de datos estructurados aptos para el entrenamiento del modelo.
3. Entrenar, optimizar y evaluar algoritmos clásicos de clasificación supervisada, eligiendo su configuración entre un conjunto fijo de alternativas y realizando pruebas de validación que aseguren un desempeño correcto sobre pacientes nuevos, en lugar de una simple memorización de los datos de entrenamiento, y medir el rendimiento de la línea base resultante mediante métricas calculadas a nivel de paciente (área bajo la curva ROC, exactitud balanceada, sensibilidad y especificidad).

4. Caracterizar el costo computacional de todo el proceso, desde el preprocesamiento de la señal cruda y la extracción de características hasta el entrenamiento, la validación y la evaluación de la línea base, en términos de tiempo de ejecución, memoria y requisitos de hardware, verificando que el sistema pueda ejecutarse en un computador de uso común sin tarjeta gráfica especializada, con el fin de consolidar un marco de referencia técnico auditable para investigaciones posteriores.

Capítulo 5

Marco Teórico

5.1 Fundamentos Clínicos y Neurofisiológicos

5.1.1 Coma Post-Paro Cardíaco

Un paro cardíaco ocurre cuando el corazón deja de bombear sangre de forma repentina, interrumpiendo el suministro de oxígeno a todo el cuerpo, incluido el cerebro. Cuando el equipo médico logra reiniciar la circulación, lo que se conoce como retorno de la circulación espontánea, una parte importante de los pacientes queda en estado de coma: una condición en la que la persona no puede despertar ni reaccionar a estímulos de su entorno, debido al daño que la falta de oxígeno provocó en el cerebro (Rossetti et al., 2016).

La evolución de este daño cerebral no es igual en todos los pacientes: algunos se recuperan por completo, mientras que otros permanecen en estado vegetativo o, en los casos más graves, no sobreviven. Por esta razón, predecir con la mayor precisión posible, y lo más temprano posible, qué tan probable es que un paciente se recupere es una de las decisiones más delicadas dentro de una Unidad de Cuidados Intensivos: de ese pronóstico depende, por ejemplo, si el equipo médico continúa o retira el soporte vital. Un error en cualquiera de los dos sentidos tiene consecuencias graves: dejar de tratar a alguien que sí podría recuperarse, o prolongar el soporte vital de alguien que no recuperará su función neurológica. Esto convierte a esta tarea en un problema clínico y ético de alta responsabilidad (Sandroni et al., 2014).

Para dimensionar el problema: cerca del 80 % de los pacientes reanimados tras un paro cardíaco llegan en estado de coma a la unidad de cuidados intensivos, y alrededor de la mitad de los que sobreviven siguen sin despertar 72 horas después (Benghanem et al., 2022; Rajajee et al., 2023).

5.1.2 El Electroencefalograma (EEG) en Cuidados Intensivos

Para apoyar esta evaluación, el personal médico recurre al electroencefalograma (EEG), una técnica de monitoreo no invasiva que registra la actividad eléctrica del cerebro mediante electrodos colocados sobre el cuero cabelludo. A diferencia de otras técnicas de imagen cerebral, el EEG no requiere trasladar al paciente fuera de la Unidad de Cuidados Intensivos y permite observar la actividad cerebral de manera continua, en tiempo real (Rayi & Murr, 2022).

En el contexto de un paciente en coma tras un paro cardíaco, el EEG permite observar patrones de actividad eléctrica cerebral asociados con distintos niveles de daño neurológico. Sin embargo, su principal limitación es que, tradicionalmente, su interpretación depende de la lectura visual de un neurofisiólogo especializado: un proceso que consume tiempo, que no siempre está disponible de forma inmediata y que resulta especialmente costoso en países con pocos recursos o en contextos donde el acceso a la salud no es equitativo, sobre todo durante las 24 horas del día que exige el monitoreo continuo en una unidad de cuidados intensivos (Herman et al., 2015). Esta limitación es uno de los puntos de partida que motivan la búsqueda de métodos automatizados de análisis, como los que se desarrollan en este trabajo de grado.

La Figura 5.1 sitúa el EEG dentro del recorrido del paciente. Tras la reanimación, el paciente ingresa en coma a la unidad de cuidados intensivos, donde puede quedar conectado a un EEG continuo durante horas o días. Durante las primeras 72 horas el tratamiento con hipotermia controlada y sedación altera el examen neurológico, por lo que las guías recomiendan no emitir un pronóstico antes de ese plazo, y hacerlo entonces combinando varias pruebas: el examen neurológico, el EEG, los potenciales evocados, los biomarcadores en sangre y las imágenes cerebrales (Rajajee et al., 2023; Sandroni et al., 2014). Ninguna de ellas decide por sí sola. El análisis automático que se propone en este trabajo se ubica en ese esquema como una prueba más: lee el EEG registrado entre las horas 24 y 72 para aportar una estimación cuantitativa en el momento de la evaluación, como apoyo al juicio del equipo médico y nunca en su lugar.

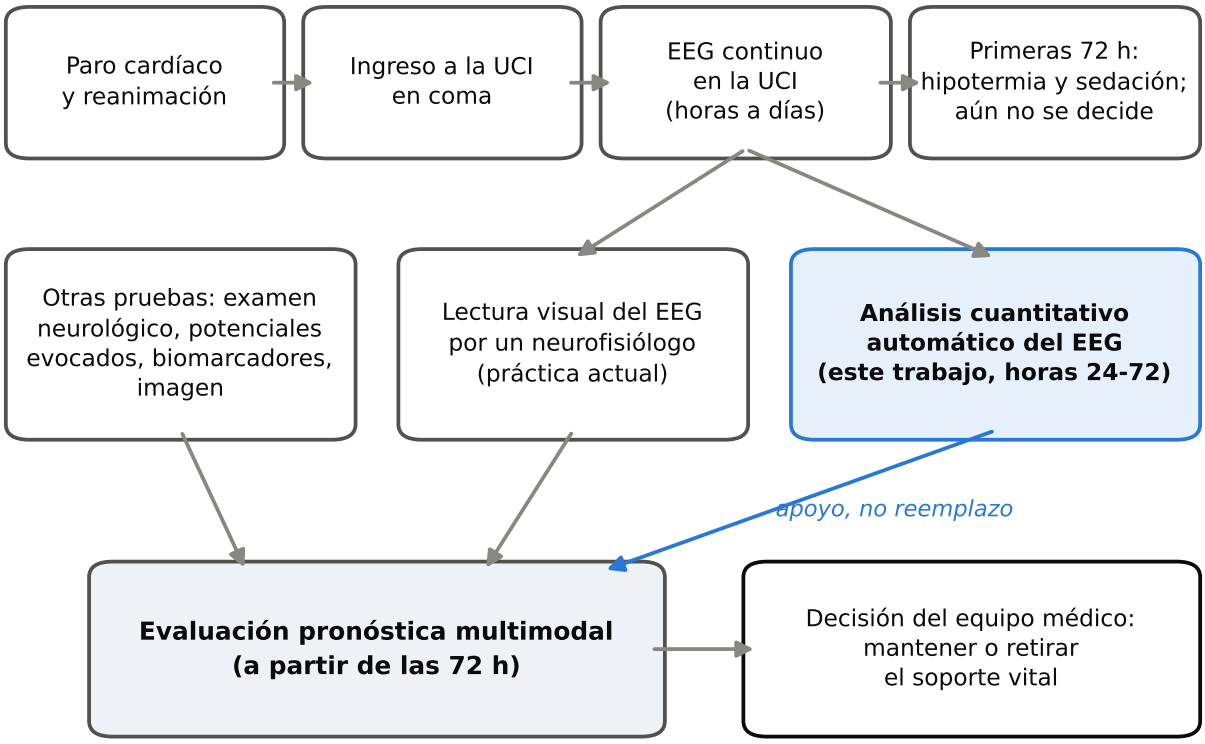


Figura 5.1: Recorrido del paciente en coma tras un paro cardíaco y lugar del EEG en la evaluación pronóstica. El análisis cuantitativo automático de este trabajo (en azul) es una fuente más de información para la evaluación multimodal que se realiza a partir de las 72 horas; no sustituye la lectura del especialista ni la decisión del equipo médico.

5.2 Procesamiento de Señales y Extracción de Características

5.2.1 Naturaleza de la Señal EEG y Artefactos

La señal de electroencefalograma capta voltajes muy pequeños generados por la actividad eléctrica del cerebro, lo que la hace especialmente sensible a interferencias externas conocidas como artefactos. Estos artefactos pueden originarse por movimientos del paciente, parpadeos, actividad muscular, o incluso por interferencia de otros equipos eléctricos presentes en una Unidad de Cuidados Intensivos. Si estas interferencias no se identifican y corrigen antes del análisis, pueden confundirse con actividad cerebral real y afectar la calidad de cualquier resultado obtenido a partir de la señal (Bigdely-Shamlo et al., 2015). Por esta razón, todo proyecto que analice EEG de forma

automatizada debe incluir una etapa de limpieza y estandarización de la señal antes de extraer cualquier característica.

En este trabajo la etapa de limpieza se concentra en los artefactos que se pueden tratar de forma automática y sobre grandes cantidades de señal, ya que no hay un especialista revisando trazo por trazo. En concreto se aplica un filtrado que descarta las frecuencias que quedan por fuera del rango de interés, un filtro adicional para eliminar la interferencia de la red eléctrica, un cambio en la referencia con la que se miden los canales para atenuar el ruido que los afecta a todos por igual, y un descarte automático de los fragmentos de señal que aparecen planos o con valores desproporcionados frente al resto del registro del propio paciente. El detalle de cada paso y sus parámetros se presenta en el Capítulo 6.

5.2.2 Conceptos Básicos para la Limpieza de la Señal

Los pasos de limpieza mencionados se apoyan en cuatro ideas que conviene presentar antes de describir cómo se aplicaron.

Frecuencia y filtros. Una señal de EEG puede entenderse como la suma de muchas ondas que oscilan a distintas velocidades. La frecuencia indica cuántas veces por segundo se repite una de esas oscilaciones y se mide en hercios (Hz): una onda de 10 Hz sube y baja diez veces cada segundo. Un filtro es un procedimiento que deja pasar ciertas frecuencias y elimina otras, de forma parecida a un colador (Sanei & Chambers, 2007). En este trabajo se emplean dos. El filtro *pasa-banda* conserva un rango de frecuencias y elimina lo que queda por debajo y por encima de él: lo muy lento, que suele deberse a desplazamientos graduales del electrodo o al sudor sobre la piel, y lo muy rápido, que suele provenir de la actividad de los músculos o de otros equipos. El filtro *notch* hace lo contrario: elimina una única frecuencia muy concreta y deja pasar todo lo demás. Se usa para retirar la interferencia de la red eléctrica, un zumbido constante a 50 o 60 Hz, según el país, que los equipos conectados a la corriente introducen en la señal (Bigdely-Shamlo et al., 2015).

Muestreo, teorema de Nyquist-Shannon y solapamiento. Un equipo digital no registra la señal de forma continua: toma mediciones a intervalos regulares, igual que una cámara de video toma fotografías sucesivas. El número de mediciones por segundo se llama frecuencia de muestreo. El teorema de Nyquist-Shannon (Shannon, 1949) establece cuántas mediciones hacen falta: para representar fielmente una onda hay que tomar al menos dos mediciones por cada una de sus oscilaciones. Por ejemplo, una onda de 10 Hz, que sube y baja diez veces por segundo, necesita al menos 20 mediciones por segundo para registrarse correctamente. En general, con una frecuencia de muestreo f_s solo pueden representarse sin distorsión las ondas más lentas que $f_s/2$, valor que se conoce como frecuencia de Nyquist. A 100 Hz, la frecuencia empleada en este trabajo, ese límite es de 50 Hz.

Si la señal contiene ondas más rápidas que ese límite, el problema no es que se pierdan, sino que se disfrazan. Es el mismo efecto que se ve en algunas películas, donde las ruedas de un carro en marcha parecen girar despacio o incluso hacia atrás: la cámara toma muy pocas fotografías por segundo para seguir el giro real y produce un movimiento falso, más lento. En una señal ocurre lo mismo: una onda demasiado rápida para la frecuencia de muestreo aparece en el registro como una onda lenta que en realidad no existe. Este efecto se llama solapamiento espectral (*aliasing*).

El solapamiento explica por qué el orden de los pasos importa. Una vez que una onda rápida se ha disfrazado de lenta, queda mezclada con la actividad cerebral real de esa misma frecuencia, y ya no hay forma de separarlas: un filtro aplicado después eliminaría las dos o ninguna. La única protección es eliminar las ondas rápidas antes de reducir la frecuencia de muestreo. Por eso en este trabajo primero se filtra y después se remuestrea.

Referencia y referencia promedio común. El voltaje no se puede medir en un solo punto: siempre es la diferencia entre dos, del mismo modo que la altura de un edificio depende de si se mide desde el nivel del mar o desde la calle. Por eso cada canal de EEG registra la diferencia entre su electrodo y un electrodo de referencia, y todo lo que afecte a esa referencia aparece copiado en todos los canales. La referencia promedio común (CAR, por sus siglas en inglés) cambia ese punto de comparación: en cada instante calcula el promedio de todos los electrodos y se lo resta a cada

uno (Sanei & Chambers, 2007). El efecto se parece al de una sala con varios micrófonos y un aire acondicionado encendido: el zumbido llega igual a todos, así que al restar lo que todos tienen en común desaparece y queda lo propio de cada voz. Esta operación tiene un punto débil: como el promedio incluye a todos los electrodos, uno que funcione mal lo contamina, y con él a todos los demás. La forma en que se manejó ese riesgo se describe en el Capítulo 6.

Puntuación z robusta. Para descartar fragmentos anómalos hay que decidir qué es «anómalo», y como las amplitudes de este conjunto de datos no están calibradas, no puede hacerse con un umbral fijo en microvoltios. La alternativa es comparar cada fragmento con los demás fragmentos del mismo paciente. La puntuación z mide justamente eso: cuánto se aleja un valor del centro del grupo, usando como unidad la dispersión típica del grupo. Un valor con $z = 0$ está en el centro; uno con $z = 4$ se aleja cuatro unidades típicas. La versión habitual usa el promedio y la desviación estándar, pero los propios valores extremos que se quieren detectar las desplazan. Es como buscar a la persona inusualmente alta de un grupo usando la estatura promedio: si en el grupo hay un gigante, el promedio sube y el gigante parece menos excepcional. La versión *robusta* usa en su lugar la mediana y la desviación absoluta mediana (MAD, por sus siglas en inglés), que apenas cambian aunque haya algunos valores extremos, de modo que los casos anómalos siguen destacando.

5.2.3 Electroencefalografía Cuantitativa (QEEG)

Tradicionalmente, el EEG se interpreta de forma visual: un especialista observa el trazado de la señal en busca de patrones conocidos. La electroencefalografía cuantitativa (QEEG, por sus siglas en inglés) propone un enfoque complementario, en el que la señal se transforma en medidas numéricas objetivas en lugar de depender únicamente de la interpretación visual (Sanei & Chambers, 2007). Este enfoque cuantitativo es el que permite, precisamente, que un modelo de aprendizaje de máquina pueda «leer» el EEG: los algoritmos no procesan imágenes ni trazados, sino los valores numéricos que resultan de este análisis cuantitativo.

La Tabla 5.1 resume las variables cuantitativas más usadas en el pronóstico del coma tras un paro cardíaco, qué mide cada una, qué suele indicar en estos pacientes y si se emplea o no en este

trabajo. Las que quedaron fuera no se descartaron por falta de interés, sino por una razón concreta que se indica en la última columna.

El significado clínico resumido en la tabla procede de las revisiones sobre pronóstico tras el paro cardíaco (Benghanem et al., 2022; Rossetti et al., 2016); la definición de las medidas de conectividad, de Sanei y Chambers (2007). Dos de las filas merecen una aclaración. La continuidad es probablemente el patrón con más peso clínico, pero su definición estándar dice que la señal está suprimida cuando su amplitud cae por debajo de un número fijo de microvoltios, y las amplitudes de este conjunto de datos no están calibradas (Sección 5.2.4); por eso aquí solo se aproxima con medidas que detectan ráfagas sin depender de la amplitud. La reactividad, por su parte, exige saber en qué momento se aplicó el estímulo, y esa información no forma parte de los registros utilizados.

Tabla 5.1: Variables de EEG cuantitativo habituales en el pronóstico del coma tras un paro cardíaco. La última columna indica si se usan en este trabajo y, cuando no, por qué.

Variable	Qué mide	Qué suele indicar tras el paro	¿Se usa aquí?
Potencia por banda	Energía de la señal en las bandas δ, θ, α, β y γ	El predominio de las bandas lentas se asocia con mayor daño cerebral	Sí, como potencia *relativa*
Cocientes entre bandas	Relación entre la energía de bandas lentas y rápidas	Resumen en un solo número el enlentecimiento de la señal	Sí
Continuidad y supresión	Proporción del tiempo en que la señal es casi plana; alternancia de ráfagas y silencios	La supresión y el patrón de ráfagas-supresión se asocian con mal pronóstico	De forma indirecta (curtosis, longitud de línea): su definición clínica usa umbrales en microvoltios
Entropía y complejidad	Qué tan irregular e impredecible es la señal	Una señal pobre y predecible sugiere actividad cerebral reducida	Sí
Reactividad	Cambio de la señal ante un estímulo externo	Su ausencia se asocia con mal pronóstico	No: el conjunto de datos no registra cuándo se estimuló al paciente
Conectividad	Grado de sincronía entre distintas regiones del cerebro	La pérdida de integración entre regiones refleja daño difuso	No: queda como trabajo futuro

5.2.4 Características Específicas: Dominio de Frecuencia y Complejidad

Una de las formas más comunes de analizar la señal de EEG es dividir su contenido en bandas de frecuencia, cada una asociada históricamente con distintos estados de actividad cerebral:

banda delta (0,5-4 Hz), theta (4-8 Hz), alfa (8-13 Hz), beta (13-30 Hz) y gamma (30-45 Hz) (Sanei & Chambers, 2007). La cantidad de energía presente en cada una de estas bandas, conocida como densidad espectral de potencia, ofrece información relevante sobre el estado del paciente: por ejemplo, un predominio marcado de actividad lenta (delta) suele asociarse con mayor daño cerebral.

Además de las bandas de frecuencia, existe otro tipo de medida conocida como entropía, la cual cuantifica qué tan predecible o irregular es una señal a lo largo del tiempo. Una señal de EEG muy plana y predecible puede indicar una actividad cerebral muy reducida, mientras que una señal con mayor irregularidad suele asociarse con una actividad cerebral más rica. Estudios previos han demostrado que las medidas de entropía son útiles para distinguir distintos estados clínicos a partir de la señal de EEG (Sabeti et al., 2009).

Las bandas de frecuencia y la entropía son los dos ejemplos más conocidos, pero no son las únicas medidas útiles. En el pronóstico del coma tras un paro cardíaco, la literatura describe tres cambios típicos en el EEG de un cerebro con daño severo: la señal se **enlentece** (la energía se desplaza hacia las bandas lentas), **pierde complejidad** (se vuelve más pobre y predecible) y puede volverse **discontinua**, alternando tramos casi planos con ráfagas de actividad. Cada uno de estos cambios se puede medir de varias formas, en el dominio de la frecuencia, en el del tiempo o con medidas de complejidad, y por eso este trabajo extrae un conjunto más amplio de características, definido en la Sección 5.2.5.

Todas esas características comparten una condición que se impuso por una razón práctica que condiciona todo el trabajo: las señales del conjunto de datos empleado vienen expresadas en unidades sin calibrar, de modo que la amplitud registrada en un paciente no es directamente comparable con la de otro. Cualquier medida que dependa del tamaño absoluto de la señal reflejaría entonces diferencias en la calibración del equipo y no diferencias en el cerebro del paciente. Por eso solo se usan medidas que **no cambian si toda la señal se multiplica por un factor**: proporciones de energía entre bandas, medidas calculadas sobre la forma del espectro y no sobre su tamaño, y medidas de entropía y de forma de la señal. Otras familias descritas en la literatura, como las

medidas de conectividad entre regiones del cerebro, quedaron fuera del alcance de esta primera versión.

5.2.5 Las Características Empleadas: Cinco Familias

Esta sección define, antes de usarlas, las 20 características que se extraen de cada época de EEG. Se agrupan en cinco familias según lo que miden, y todas cumplen la condición de no depender de la amplitud absoluta de la señal descrita en la sección anterior. Varias de ellas se calculan sobre el espectro de potencia, que describe cuánta energía tiene la señal en cada frecuencia; en adelante se escribe $P(f)$ para la potencia en la frecuencia f, dentro del rango de 0,5 a 45 Hz que conserva el filtrado (Sección 5.2.2).

1. Potencia relativa (5 características). Es la fracción de la energía total que cae en cada una de las cinco bandas (δ, θ, α, β y γ). Se puede pensar como una torta repartida en cinco porciones: lo que se mide no es el tamaño de la torta, que depende de la calibración del equipo, sino qué porción le corresponde a cada banda. Para una banda b:

$$P_{\text{rel}}(b) = \frac{\sum_{f \in b} P(f)}{\sum_{f=0,5}^{45} P(f)}.$$

Las cinco porciones suman siempre 1. Un cerebro con daño severo desplaza la torta hacia las bandas lentas, de modo que la porción de δ crece a costa de α y β.

2. Cocientes entre bandas (4 características). Dividen la potencia de unas bandas entre la de otras para resumir el enlentecimiento en un solo número: α/δ, θ/α, α/θ y $(\delta + \theta)/(\alpha + \beta)$, este último conocido como cociente entre actividad lenta y rápida. Si la señal se enlentece, los cocientes con la banda lenta en el denominador bajan y los que la tienen en el numerador suben.

3. Forma del espectro (4 características). En lugar de mirar bandas por separado, estas medidas describen el espectro completo:

- La **entropía espectral** mide qué tan repartida está la energía entre las frecuencias. Se normaliza entre 0 y 1: vale cerca de 1 si la energía se reparte por igual en todo el rango, y cerca de 0 si se concentra en unas pocas frecuencias, como ocurre cuando una sola onda lenta domina la señal.
- La **frecuencia de borde espectral** (SEF, por sus siglas en inglés) es la frecuencia por debajo de la cual se acumula un porcentaje dado de la energía. La SEF50 marca la mitad de la energía y la SEF95 el 95 %, es decir, hasta dónde llega el espectro en la práctica. Si la señal se enlentece, las dos bajan.
- El **centroide espectral** es el centro de gravedad del espectro, la frecuencia promedio ponderada por la energía de cada una: $\sum f\, P(f) \,/\, \sum P(f)$.

4. Dominio del tiempo (5 características). Estas medidas se calculan directamente sobre la forma de la onda, sin pasar por el espectro:

- Los **parámetros de Hjorth** (Hjorth, 1970) describen la onda a partir de sus variaciones. Si x es la señal y x' su primera diferencia (cuánto cambia de una muestra a la siguiente), la *movilidad* es $\sqrt{\mathrm{var}(x')/\mathrm{var}(x)}$ y funciona como una estimación de la frecuencia media vista desde el tiempo. La *complejidad* es la movilidad de x' dividida entre la movilidad de x, y mide qué tanto se aleja la onda de una sinusoide pura, que tiene complejidad 1. Hjorth definió además un tercer parámetro, la *actividad*, que es la varianza de la señal; ese no se usa, porque crece con la amplitud y por tanto depende de la calibración.
- La **longitud de línea normalizada** es la longitud total del trazo, la suma de los saltos $|x_{t+1} - x_t|$ a lo largo de la época, dividida entre la desviación estándar de la propia época. Mide cuánto camino recorre la señal por unidad de amplitud: un trazo lento y suave recorre poco, uno rápido y quebrado recorre mucho.
- La **tasa de cruces por cero** es la fracción de pasos en los que la señal, una vez centrada en su media, cambia de signo. Es una forma sencilla de estimar la frecuencia dominante: una onda lenta cruza el cero pocas veces y una rápida muchas.

- La **curtosis** mide qué tan pesadas son las colas de la distribución de amplitudes, es decir, si la época contiene unos pocos valores muy alejados del resto. Una señal casi plana interrumpida por ráfagas aisladas, que es el sello de la discontinuidad, tiene una curtosis alta.

5. Complejidad y asimetría (2 características).

- La **entropía de permutación** (Bandt & Pompe, 2002) mira el orden de los valores y no su tamaño. Se recorre la época tomando grupos de tres muestras consecutivas y se anota su patrón: por ejemplo, «sube y luego baja» o «baja dos veces seguidas». Con tres muestras hay seis patrones posibles. Si la señal es irregular, los seis aparecen con frecuencias parecidas y la entropía, normalizada entre 0 y 1, se acerca a 1; si la señal es pobre y repetitiva, unos pocos patrones dominan y la entropía baja.
- La **asimetría** (*skewness*) es una medida estadística: indica si la distribución de amplitudes de un canal se carga más hacia los valores positivos o hacia los negativos, por ejemplo cuando la señal tiene picos marcados en una sola dirección. Conviene no confundirla con la asimetría entre hemisferios que se usa en la lectura clínica del EEG: aquí no se compara el lado izquierdo con el derecho, sino que se describe la forma de la distribución de valores dentro de un mismo canal.

Las cinco familias responden a los tres cambios descritos en la sección anterior: el enlentecimiento lo capturan las potencias relativas, los cocientes y la forma del espectro; la pérdida de complejidad, las entropías y los parámetros de Hjorth; y la discontinuidad, la curtosis y la longitud de línea normalizada. Cómo se calculó cada una sobre los datos, y la comprobación de que ninguna depende de la amplitud, se describen en la Sección 6.2.3.

5.2.6 Ingeniería de Características

El proceso de convertir una señal cruda de EEG en un conjunto de valores numéricos que un algoritmo de aprendizaje de máquina pueda utilizar se conoce como ingeniería de características. En lugar de entregarle al modelo la señal completa, se le entregan medidas ya calculadas: la potencia

de cada banda de frecuencia mencionada anteriormente, la entropía de la señal, o relaciones entre distintas bandas (por ejemplo, la razón entre la potencia delta y la potencia alfa). Este enfoque es, precisamente, lo que distingue a los modelos de aprendizaje de máquina clásico de los modelos de aprendizaje profundo: mientras estos últimos aprenden a extraer características directamente de la señal cruda, los primeros dependen de que dichas características se definan explícitamente antes del entrenamiento, lo que a cambio ofrece modelos más simples, más rápidos de entrenar y más fáciles de interpretar (Saeidi et al., 2021).

Conviene matizar que estas ventajas no son automáticas ni universales. Que un modelo clásico resulte más simple, más barato de entrenar o más fácil de interpretar depende del problema, del algoritmo concreto y de la cantidad de características que se le entreguen: un modelo clásico alimentado con cientos de características y construido sobre muchos árboles combinados puede ser tan difícil de interpretar como una red profunda pequeña. Lo que sí se sostiene de forma general es la diferencia en la cantidad de datos y en el hardware que cada paradigma necesita.

5.3 Aprendizaje de Máquina (Machine Learning) en Pronóstico Clínico

5.3.1 Paradigma Clásico vs. Aprendizaje Profundo

Dentro del aprendizaje de máquina existen, de forma general, dos grandes paradigmas. El primero es el aprendizaje de máquina clásico, conformado por algoritmos que aprenden a partir de características ya definidas y calculadas previamente por una persona (como las descritas en la Sección 5.2). El segundo es el paradigma del aprendizaje profundo, que aprende directamente a partir de los datos crudos, sin necesidad de que un experto defina de antemano qué medidas son relevantes (Ezugwu et al., 2025).

Ambos paradigmas tienen ventajas y desventajas. Los modelos de aprendizaje profundo suelen alcanzar un rendimiento muy alto, pero a cambio requieren grandes volúmenes de datos y hardware especializado para su entrenamiento, y su funcionamiento interno es difícil de interpretar (el problema de «caja negra» mencionado en el Capítulo 2). Los modelos clásicos, en cambio,

son más simples y óptimos en tiempo de entrenamiento, y al basarse en características explícitas y conocidas es más fácil explicar por qué el modelo llegó a una conclusión determinada. Esa ventaja, sin embargo, tiene un precio. En el enfoque clásico el trabajo difícil se traslada a decidir qué características calcular, una elección que exige conocimiento del problema y de la que depende buena parte del resultado: si las medidas escogidas no capturan lo que distingue a los grupos, ningún algoritmo podrá encontrarlo. En el aprendizaje profundo esa decisión la toma el propio modelo durante el entrenamiento, de modo que el mayor tiempo que tarda en entrenarse compensa, en ocasiones, la dificultad de saber de antemano qué variables usar.

Además de la interpretabilidad y del costo computacional, hay una razón relacionada con el tamaño del conjunto de datos de este trabajo. Los modelos de aprendizaje profundo tienen que descubrir por su cuenta qué medidas de la señal son relevantes, y para lograrlo necesitan muchos ejemplos distintos; en este caso cada ejemplo es un paciente, y los pacientes disponibles son pocos. Al entregarle al modelo características ya definidas a partir del conocimiento neurofisiológico existente, el enfoque clásico aprovecha ese conocimiento en lugar de tener que redescubrirlo, y reduce el riesgo de que el modelo termine ajustándose a las particularidades de los pocos pacientes disponibles en vez de a lo que tienen en común.

5.3.2 Modelos Supervisados de Clasificación

La tarea que aborda este proyecto corresponde a un problema de clasificación binaria supervisada: a partir de las características extraídas del EEG de un paciente, el modelo debe predecir a cuál de dos categorías pertenece (pronóstico neurológico favorable o desfavorable), aprendiendo dicha relación a partir de ejemplos de pacientes previos cuyo desenlace ya se conoce. Este proyecto evalúa cuatro algoritmos clásicos de clasificación:

- **Regresión Logística:** un modelo estadístico que estima la probabilidad de que un caso pertenezca a una categoría, a partir de una combinación de las características de entrada. Es uno de los modelos más simples e interpretables disponibles, y suele usarse como punto de referencia inicial en problemas de clasificación clínica (Ezugwu et al., 2025).

- **Máquinas de Vectores de Soporte (SVM):** un algoritmo que busca la frontera de decisión óptima que separa ambas categorías en el espacio de características, maximizando el margen entre ellas (Cortes & Vapnik, 1995).
- **Bosques Aleatorios (Random Forest):** un algoritmo que combina múltiples árboles de decisión entrenados sobre distintos subconjuntos de los datos, y promedia sus resultados para obtener una predicción más robusta y menos propensa a errores por casos particulares (Breiman, 2001).
- **Potenciación del Gradiente (Gradient Boosting):** un algoritmo que también se apoya en árboles de decisión, pero los construye uno tras otro en lugar de en paralelo: cada árbol nuevo se entrena para corregir los errores que cometieron los anteriores. Suele dar buenos resultados en tablas de datos como la que se construye en este trabajo, donde cada fila es un fragmento de señal y cada columna una característica medida.

Estos cuatro algoritmos se escogieron porque cubren maneras distintas de separar dos grupos, de modo que la comparación no queda atada a una sola forma de mirar los datos: la regresión logística traza una frontera recta, las máquinas de vectores de soporte permiten una frontera curva, y los bosques aleatorios y la potenciación del gradiente construyen la decisión combinando muchos árboles (Figura 5.2). Los cuatro comparten además algo necesario cuando se tienen muchas más características medidas que pacientes disponibles: permiten controlar qué tanto se ajusta el modelo a los datos con los que se entrena. La exploración se limitó a estas cuatro familias. Otros métodos clásicos de uso frecuente, como k vecinos más cercanos y Naive Bayes, no se incluyeron porque la teoría en la que se apoyan anticipa que no serían adecuados para datos con las características de los de este trabajo. El primero clasifica a un paciente según a cuáles otros se parece más, y pierde poder cuando cada caso se describe con muchas características, porque las distancias entre casos se vuelven todas parecidas y dejan de distinguir. El segundo parte de suponer que las características no guardan relación entre sí, suposición que no se cumple cuando una misma medida se repite sobre varios canales vecinos del cuero cabelludo, que registran información muy parecida. Cómo se aplicó este criterio a los datos concretos de este trabajo se detalla en el Capítulo 6.

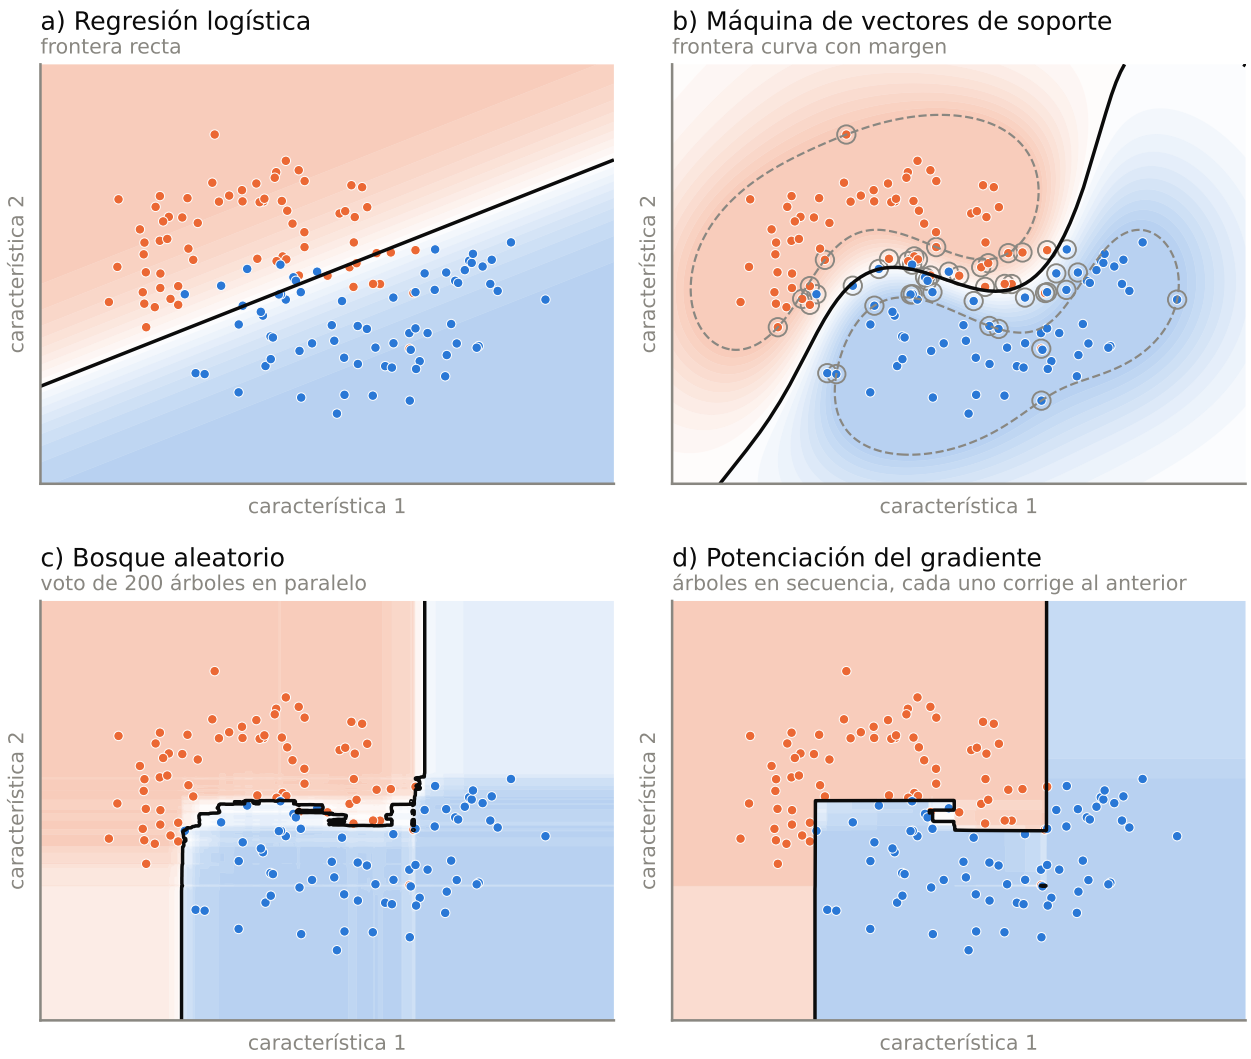


Figura 5.2: Frontera de decisión que traza cada uno de los cuatro algoritmos al separar dos grupos de puntos (naranja y azul). Los cuatro se entrenaron sobre el mismo conjunto de datos **sintéticos**, de solo dos características para poder dibujarlo, que no provienen de este estudio: la figura ilustra cómo decide cada algoritmo, no mide nada del proyecto. La línea negra es la frontera y el color de fondo, el grupo que el modelo asignaría a cada punto del plano. a) La regresión logística traza una recta. b) La máquina de vectores de soporte traza una curva; las líneas punteadas marcan el margen y los puntos rodeados son los vectores de soporte, los únicos que definen la frontera. c) y d) Los dos métodos basados en árboles dividen el plano en escalones, porque cada árbol solo puede hacer cortes paralelos a los ejes; el bosque aleatorio promedia 200 árboles entrenados en paralelo y la potenciación del gradiente los construye uno tras otro, con la misma profundidad máxima de 3 empleada en el modelo final de este trabajo.

5.3.3 Métricas de Evaluación de Rendimiento y Validación

Para determinar si un modelo funciona correctamente, no basta con observar su desempeño sobre los mismos datos con los que fue entrenado: es necesario evaluarlo sobre datos que no vio

durante el entrenamiento, para saber si realmente aprendió un patrón útil o si simplemente memorizó los ejemplos que se le mostraron. Este proyecto emplea validación cruzada, agrupada de forma que todas las épocas de un mismo paciente permanezcan siempre juntas, ya sea completamente en el grupo de entrenamiento o completamente en el grupo de prueba, evitando así que el modelo sea evaluado con datos del mismo paciente que ya observó durante el entrenamiento, un error metodológico conocido que puede hacer que el rendimiento reportado de un modelo parezca artificialmente más alto de lo que realmente es (Varoquaux & Cheplygina, 2022).

Antes de describirlas conviene fijar qué significa acertar en este trabajo, porque de ello depende la lectura de todas las métricas. Lo que el modelo intenta anticipar no es si el paciente despertará, sino si tendrá un *desenlace neurológico favorable* (CPC 1-2). Como se detalla al presentar la escala CPC (sección 6.2.1), esa distinción no es un matiz de redacción: un paciente puede recobrar la consciencia y aun así quedar clasificado como desenlace desfavorable, porque depende de otras personas para vivir. En adelante, cada vez que se hable de acertar o de reconocer a un paciente, se hace referencia a esa clasificación entre desenlace favorable y desfavorable, y no a la recuperación de la consciencia.

Para medir el rendimiento del modelo se utilizan varias métricas complementarias, ya que ninguna por sí sola da una imagen completa. Todas parten de comparar el pronóstico del modelo con el desenlace real de cada paciente, tomando como clase positiva el desenlace favorable. De esa comparación salen cuatro conteos: los verdaderos positivos (VP), pacientes con desenlace favorable que el modelo reconoce como tales; los falsos negativos (FN), pacientes con desenlace favorable que el modelo da por desfavorables; y, del mismo modo para los pacientes con desenlace desfavorable, los verdaderos negativos (VN) y los falsos positivos (FP). La *sensibilidad* es la proporción de pacientes con desenlace favorable que el modelo reconoce, y la *especificidad*, la proporción de pacientes con desenlace desfavorable que reconoce:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}, \qquad \text{Especificidad} = \frac{VN}{VN + FP} \tag{5.1}$$

La *exactitud balanceada* es el promedio de las dos:

$$\text{Exactitud balanceada} = \frac{\text{Sensibilidad} + \text{Especificidad}}{2} \tag{5.2}$$

Se prefiere a la exactitud simple, la proporción de aciertos sobre el total, porque esta última puede resultar alta en un modelo que acierta casi siempre con el grupo más numeroso y casi nunca con el otro; al promediar las dos proporciones, cada grupo pesa lo mismo sin importar cuántos pacientes tenga.

La métrica principal de este trabajo es el área bajo la curva ROC, que se abrevia AUC-ROC. Vale la pena explicarla con un ejemplo, porque su nombre no dice mucho. Imaginemos que se toman dos pacientes: uno que tuvo un desenlace favorable y uno que no. Al modelo se le pide una calificación para cada uno, es decir, qué tan probable le parece que ese paciente alcance un desenlace favorable. La pregunta es sencilla: ¿le puso la calificación más alta al que de verdad lo alcanzó? Ahora repitamos eso con todas las parejas que se puedan formar, cada paciente con desenlace favorable contra cada paciente con desenlace desfavorable. El AUC-ROC es el porcentaje de parejas en las que el modelo acertó el orden. Si vale 1,0, acertó en todas. Si vale 0,5, acertó en la mitad, que es lo mismo que habría logrado lanzando una moneda para decidir cuál de los dos va primero, o sea que el modelo no aporta ninguna información. Esta manera de contarlo no es una versión simplificada de la métrica: es lo que la métrica mide realmente (Hanley & McNeil, 1982). En términos formales, si F es el conjunto de los n_1 pacientes con desenlace favorable, D el de los n_0 pacientes con desenlace desfavorable y s_i la calificación que el modelo asigna al paciente i:

$$\text{AUC} = \frac{1}{n_1\, n_0} \sum_{i \in F} \sum_{j \in D} \left[\mathbf{1}(s_i > s_j) + \tfrac{1}{2}\, \mathbf{1}(s_i = s_j) \right] \tag{5.3}$$

donde $\mathbf{1}(\cdot)$ vale 1 cuando se cumple la condición y 0 cuando no, de modo que cada pareja bien ordenada suma un acierto y cada empate, medio.

Sobre ese 0,5 hay que hacer una aclaración. Ese es el valor del azar en el caso ideal: muchos pacientes y la misma cantidad en cada grupo. Cuando se trabaja con pocos pacientes y la validación

se hace dejando uno por fuera cada vez, el azar deja de valer 0,5 y puede quedar por debajo, así que compararse contra 0,5 llevaría a creer que el modelo funciona mejor de lo que en realidad funciona. Por eso en este trabajo el valor del azar no se dio por supuesto: se midió. Para medirlo se barajaron al azar las etiquetas de los pacientes, es decir, quién alcanzó un desenlace favorable y quién no, y se volvió a correr el mismo procedimiento de validación muchas veces, para ver qué puntaje sale cuando por construcción no hay nada que aprender. El resultado de esa medición se reporta en el Capítulo 7 y es el valor contra el que se compara el modelo.

Estas métricas no pesan todas lo mismo para el problema clínico que se quiere apoyar. Conviene notar primero que el modelo no responde con un sí o un no, sino con un número entre 0 y 1 que indica qué tan probable considera un desenlace favorable para el paciente. Para convertir ese número en una decisión hay que escoger a partir de qué valor se dice que sí, y ese punto de corte es lo que se llama umbral. La exactitud balanceada, la sensibilidad y la especificidad cambian según dónde se ponga ese corte, mientras que el AUC-ROC no cambia, porque solo mira el orden en que el modelo dejó a los pacientes. Esa es la razón por la que el AUC-ROC, calculado sobre pacientes y no sobre fragmentos de señal, es la métrica principal de este trabajo. Aun así, la sensibilidad y la especificidad se reportan aparte, porque los dos errores posibles no cuestan lo mismo: dar por perdido a un paciente que sí habría tenido un desenlace favorable es el error grave, ya que puede respaldar la decisión de retirar el soporte vital a alguien que todavía tenía posibilidades, mientras que el error contrario prolonga una atención que al final no va a servir. Un modelo con un AUC-ROC aceptable pero que casi nunca reconoce a los pacientes con desenlace desfavorable no sería utilizable en la práctica.

Además, como el modelo entrega una probabilidad y no solo una clase, se mide también qué tan acertada es esa probabilidad con la *puntuación de Brier*, el error cuadrático medio entre la probabilidad asignada p_i y el desenlace real y_i (1 si fue favorable, 0 si no), sobre los N pacientes evaluados:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^{N} (p_i - y_i)^2 \tag{5.4}$$

Vale 0 para un modelo que asigna probabilidad 1 a todo lo que ocurrió y 0 a todo lo que no, y 0,25 para uno que responde 0,5 a todos los pacientes, es decir, para uno que no se compromete con ninguna respuesta.

Por último, en la muestra de pacientes que se usó en este trabajo la cantidad de pacientes con desenlace favorable y la de los que tuvieron un desenlace desfavorable son parecidas, lo cual hace más fácil leer las métricas. Hay que aclarar que eso se debe a la forma en que se escogió la muestra y no a que las dos situaciones sean igual de frecuentes en la realidad: en el conjunto de datos I-CARE completo los desenlaces desfavorables son bastante más. Esta diferencia se retoma como limitación en el Capítulo 8.

Capítulo 6

Metodología

6.1 Selección y Justificación de la Metodología

Este proyecto adopta la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), un estándar ampliamente utilizado en proyectos de análisis de datos y aprendizaje de máquina (Schröer et al., 2021). A diferencia de los modelos de desarrollo de software tradicionales (como el modelo en cascada), que asumen requisitos fijos desde el inicio, CRISP-DM es un proceso iterativo: permite regresar a fases anteriores cuando un hallazgo nuevo lo exige.

Esta característica es especialmente adecuada para el presente proyecto, dado que la señal de EEG es una fuente de datos ruidosa e impredecible, cuyas particularidades (formatos heterogéneos, frecuencias de muestreo distintas entre pacientes, calidad variable de las grabaciones) solo se descubren a medida que se explora el dataset real. CRISP-DM organiza el trabajo en seis fases generales: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Las siguientes secciones describen cómo se aplicó cada una de estas fases en el desarrollo del proyecto.

El carácter iterativo de CRISP-DM no fue solo una elección teórica: el desarrollo tuvo que volver sobre fases ya cerradas en dos ocasiones. La primera ocurrió durante la preparación de los datos, al detectar que la re-referencia por promedio común podía reactivar un electrodo desconectado a mitad de un registro, convirtiendo un tramo plano en una señal aparentemente válida; corregirlo obligó a regresar al preprocesamiento y reprocesar a los pacientes afectados. La segunda ocurrió al pasar a la extracción de características, al comprobar que las señales de I-CARE están expresadas en unidades sin calibrar y que su amplitud llega a variar veintinueve veces entre pacientes, lo que obligó a descartar toda medida basada en la potencia absoluta y a rediseñar el conjunto de características en torno a medidas que no dependen de la escala de la señal. En ambos

casos el hallazgo apareció en una fase posterior y obligó a corregir una anterior, que es justamente el recorrido que esta metodología contempla.

6.2 Fases de Desarrollo del Proyecto

6.2.1 Comprensión del Entorno y los Datos

El proyecto utiliza la base de datos I-CARE (International Cardiac Arrest Research Consortium), en su versión 2.1, publicada a través de la plataforma PhysioNet (Amorim et al., 2023; Goldberger et al., 2000). Esta base de datos reúne registros de electroencefalograma continuo de pacientes en estado de coma tras un paro cardíaco, junto con su desenlace neurológico observado.

El desenlace neurológico de cada paciente se mide con la escala CPC (Cerebral Performance Category), que resume en cinco niveles la situación de la persona meses después del paro cardíaco:

1. Buen desempeño cerebral: la persona es independiente para las actividades de la vida diaria.
2. Discapacidad moderada: quedan secuelas, pero la persona sigue siendo independiente.
3. Discapacidad severa: la persona está consciente, pero depende de otros para vivir.
4. Estado vegetativo, denominado también síndrome de vigilia sin respuesta.
5. Muerte.

I-CARE agrupa estos cinco niveles en dos categorías: se considera desenlace favorable el CPC 1 y el CPC 2, y desfavorable el CPC 3, el 4 y el 5. Conviene detenerse en dónde queda esa línea, porque no coincide con la lectura intuitiva. La frontera no separa a los pacientes que recuperan la consciencia de los que no: un paciente con CPC 3 despierta, está consciente y puede comunicarse, y aun así pertenece a la categoría desfavorable. Incluso el CPC 4 conserva ciclos de sueño y vigilia, y de ahí procede el nombre de síndrome de vigilia sin respuesta. Lo que separa realmente a las dos categorías es la independencia funcional, es decir, si la persona podrá valerse por sí misma. Ese es el criterio que emplea la práctica clínica habitual y es el que adopta este trabajo. La figura 6.1 resume la escala completa y sitúa la línea de corte.



Figura 6.1: La escala CPC de 1 a 5 y la línea que separa las dos clases del problema. El corte no está en la recuperación de la consciencia sino en la independencia funcional: los pacientes con CPC 3 y CPC 4 están despiertos y aun así pertenecen a la clase desfavorable. La columna de la derecha se incluye precisamente para mostrar que las dos cosas no coinciden.

Conviene precisar además cuándo se mide ese desenlace. La etiqueta de I-CARE corresponde al mejor CPC alcanzado entre los tres y los seis meses posteriores al paro cardíaco, y no al estado del paciente al salir del hospital (Amorim et al., 2023). El problema que aborda este trabajo queda entonces formulado de la siguiente manera: a partir del electroencefalograma registrado durante las primeras horas, estimar si su desenlace neurológico será favorable varios meses después.

Organización de los datos. Los datos están organizados por paciente. Cada paciente corresponde a una carpeta identificada por un número, y dentro de ella la grabación no aparece como un archivo único, sino repartida en varios archivos llamados segmentos. Cada segmento se nombra siguiendo el patrón de identificador del paciente, número de segmento y hora, e incluye dos archivos: uno de texto con la descripción técnica de la señal y otro binario con los valores registrados. El archivo de texto indica cuántos canales contiene el registro, a qué frecuencia fue muestreado, cuántos valores almacena y el nombre de cada electrodo. La figura 6.2 muestra uno de esos archivos tal como viene en el conjunto de datos, junto al esquema de las tres unidades en que se organiza la información.

a) Cabecera real de un segmento

```
0284_025_024_EEG 19 500 229500
0284_025_024_EEG.mat 16+24 526.7411150516...
0284_025_024_EEG.mat 16+24 434.0673958030...
0284_025_024_EEG.mat 16+24 796.9931195947...
        ...  (19 canales en total)  ...
#Utility frequency: 50
#Start time: 24:00:00
#End time: 24:07:38
```

archivo: 0284_025_024_EEG.hea

19 canales · 500 Hz · 229 500 muestras

unidades sin calibrar de amplitud (/nu)

hora absoluta desde el paro: 24 h

b) Cómo se organizan los datos

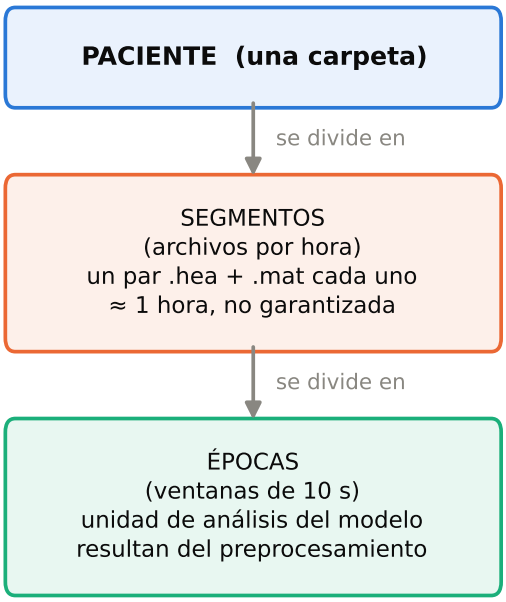


Figura 6.2: a) Archivo de descripción técnica de un segmento real del paciente 0284, correspondiente a la hora 24. Se han resaltado los tres datos que condicionan el preprocesamiento: los 19 canales muestreados a 500 Hz, las unidades de amplitud sin calibrar (indicadas con el sufijo /nu) y la hora absoluta desde el paro cardíaco. La ausencia de calibración es la razón por la que el rechazo de épocas no puede apoyarse en un umbral fijo de microvoltios. b) Las tres unidades en que se organiza la información: el paciente, los segmentos en que se reparte su grabación y las épocas de diez segundos que resultan del preprocesamiento.

La hora que aparece en el nombre del segmento es absoluta: indica cuántas horas habían transcurrido desde el paro cardíaco, y no cuánto tiempo llevaba grabando el equipo. Esta distinción importa porque las grabaciones se interrumpen con frecuencia, por traslados del paciente o por procedimientos médicos, y al reanudarse retoman la hora que corresponde. Un paciente puede tener así huecos en su numeración sin que se pierda la referencia temporal.

Conviene advertir que un segmento no equivale necesariamente a una hora de señal. Al revisar los archivos se encontró que una misma hora puede venir repartida en dos segmentos cuyas duraciones suman aproximadamente sesenta minutos, y también que hay horas que contienen bastante menos señal de la que su nombre sugiere: en el paciente 0284, por ejemplo, la hora 25 aporta únicamente veintinueve minutos de grabación. Contar segmentos no es entonces lo mismo que contar horas de señal disponible.

Cada segmento se almacena además en tres versiones según el tipo de señal que recoge: electroencefalograma, electrocardiograma y un tercer grupo con otras señales fisiológicas. Este trabajo utiliza únicamente los archivos de electroencefalograma; los demás permanecen sin utilizar.

Por último, conviene distinguir dos unidades que se parecen en el nombre pero designan cosas distintas. Un segmento es uno de estos archivos de grabación, tal como viene descargado. Una época es una ventana de diez segundos que se obtiene al dividir la señal ya limpia, y es la unidad sobre la que trabaja el modelo. El procedimiento que produce esas épocas se describe en la sección 6.2.2, dedicada al preprocesamiento; de aquí en adelante ambos términos se emplean siempre con ese significado.

La ventana de tiempo utilizada. Para la construcción del modelo se definió una ventana de tiempo de interés entre las 24 y las 72 horas posteriores al retorno de la circulación espontánea. La razón es clínica. Durante las primeras horas después de la reanimación el paciente permanece sedado y con la temperatura del cuerpo bajada a propósito, que en esta base de datos se fija en 33 o en 36 grados según el caso. Las dos cosas apagan parcialmente la actividad eléctrica del cerebro, de modo que lo que se registra en ese período no muestra cómo está realmente el cerebro del paciente, sino el efecto de los medicamentos y del frío. Las guías clínicas de pronóstico lo señalan de forma expresa: la sedación altera el electroencefalograma, y la recomendación es evaluar al paciente cuando ya no está bajo su efecto (Rajajee et al., 2023). A partir de las 24 horas el sedante comienza a perder efecto y el paciente empieza a recuperar temperatura, y es entonces cuando la señal empieza a mostrar información propia de su estado neurológico.

El extremo superior de la ventana proviene de la literatura sobre pronóstico neurológico tras un paro cardíaco, que sitúa en torno a las 72 horas el punto en que el estado del paciente resulta más informativo (Benghanem et al., 2022; Rajajee et al., 2023). Conviene aclarar una diferencia con esa misma literatura: las guías recomiendan esperar 72 horas antes de emitir un pronóstico clínico, porque esa decisión puede llevar a retirar el soporte vital y exige la mayor certeza posible. Este trabajo no toma esa decisión, sino que aprovecha la señal disponible en todo el rango de 24 a

72 horas para entrenar el modelo, de manera que el límite superior de la ventana coincide con el momento que las guías señalan como más informativo.

La elección se confirmó además durante la exploración inicial de los datos. Al revisar la disponibilidad real de los registros se observó que la mayoría de los pacientes cuenta con grabaciones que se extienden bastante más allá de las 24 horas, mientras que unos pocos se interrumpen mucho antes.

Los pacientes utilizados. La base completa del consorcio I-CARE reúne registros de 1020 pacientes, de los cuales 607 se publican como conjunto de entrenamiento en PhysioNet (Amorim et al., 2023). Este trabajo, planteado como una línea base, emplea un subconjunto de 35 pacientes descargados. De ellos, 20 se destinaron al desarrollo del modelo y 15 se reservaron como conjunto de prueba retenido, que el modelo vería una única vez y al final del proceso.

Criterios de inclusión y exclusión. Para entrar en la muestra, un paciente debía pertenecer al conjunto público de I-CARE y tener registrada su etiqueta de desenlace. La asignación a cada conjunto se hizo con esa etiqueta, como se detalla enseguida, y antes de abrir ninguna señal. Fijada la división, se aplicó un único criterio de exclusión: no tener ningún registro de EEG dentro de la ventana de 24 a 72 horas, que dejó fuera a cuatro de los 35. No se empleó ningún otro criterio clínico, como la edad, el hospital o el ritmo cardíaco inicial.

Qué clase de conjunto de prueba es. El conjunto de prueba es una **partición retenida de la misma base I-CARE**, no una cohorte externa independiente: sus pacientes proceden de los mismos hospitales y del mismo protocolo de registro que los de desarrollo, con la única salvedad del hospital D, que se describe más adelante. Por eso protege frente a la fuga de información entre el desarrollo y la evaluación, pero no mide si el modelo se generaliza a otros centros u otras poblaciones; esa validación externa queda como trabajo futuro.

Los 20 pacientes de desarrollo se seleccionaron buscando de manera deliberada un balance entre las dos clases, con diez desenlaces favorables y diez desfavorables. Esta decisión conviene declararla porque tiene consecuencias sobre la interpretación de los resultados. En la base completa

del consorcio, 369 pacientes (36 %) alcanzaron un desenlace favorable, mientras que 48 (5 %) quedaron con discapacidad severa y 603 (59 %) fallecieron (Amorim et al., 2023), es decir, alrededor de un 36 % de desenlaces favorables frente a un 64 % desfavorables. La muestra empleada aquí se acerca en cambio al 51 % y al 49 %. Está entonces enriquecida en desenlaces favorables y no reproduce las proporciones reales de la población. Para una prueba de concepto esto resulta conveniente, ya que permite observar el comportamiento del sistema sin que el desbalance interfiera en la lectura, pero implica que los resultados obtenidos no pueden extrapolarse de forma directa a la distribución real de pacientes.

La forma de elegir los pacientes fue distinta en cada uno de los dos conjuntos, y esa diferencia tiene consecuencias que conviene dejar dichas desde ahora. Para armar el conjunto de desarrollo se revisó el nivel exacto de la escala CPC de cada paciente, porque solo así era posible componer el balance de diez y diez descrito arriba. Para el conjunto de prueba retenido, en cambio, únicamente se consultó la etiqueta de desenlace, es decir, si el paciente figuraba como favorable o desfavorable, hasta reunir quince. En ninguno de los dos casos se abrió ni se examinó una sola señal de electroencefalograma antes de fijar la división, ni se consultaron los datos clínicos como el hospital de procedencia, la edad o el ritmo cardíaco inicial. Esa condición es la que sostiene el papel del conjunto de prueba retenido como resguardo frente a la fuga de información: los pacientes que sirvieron para medir el resultado final se apartaron antes de mirar nada que el modelo pudiera aprovechar.

Conviene añadir un detalle sobre esa división. Los identificadores de los pacientes de los dos conjuntos no ocupan tramos separados de la base de datos, sino que aparecen entremezclados a lo largo de todo el rango, y de hecho los identificadores más altos de los 35 pertenecen al conjunto de desarrollo. Esto descarta que las diferencias que se describen más adelante entre un conjunto y otro puedan atribuirse a que procedan de zonas distintas del registro original, con equipos o protocolos de grabación diferentes. La figura 6.3 presenta los 35 pacientes ordenados por identificador y permite comprobarlo de un vistazo, mientras que la tabla 6.1 recoge el detalle de cada uno.

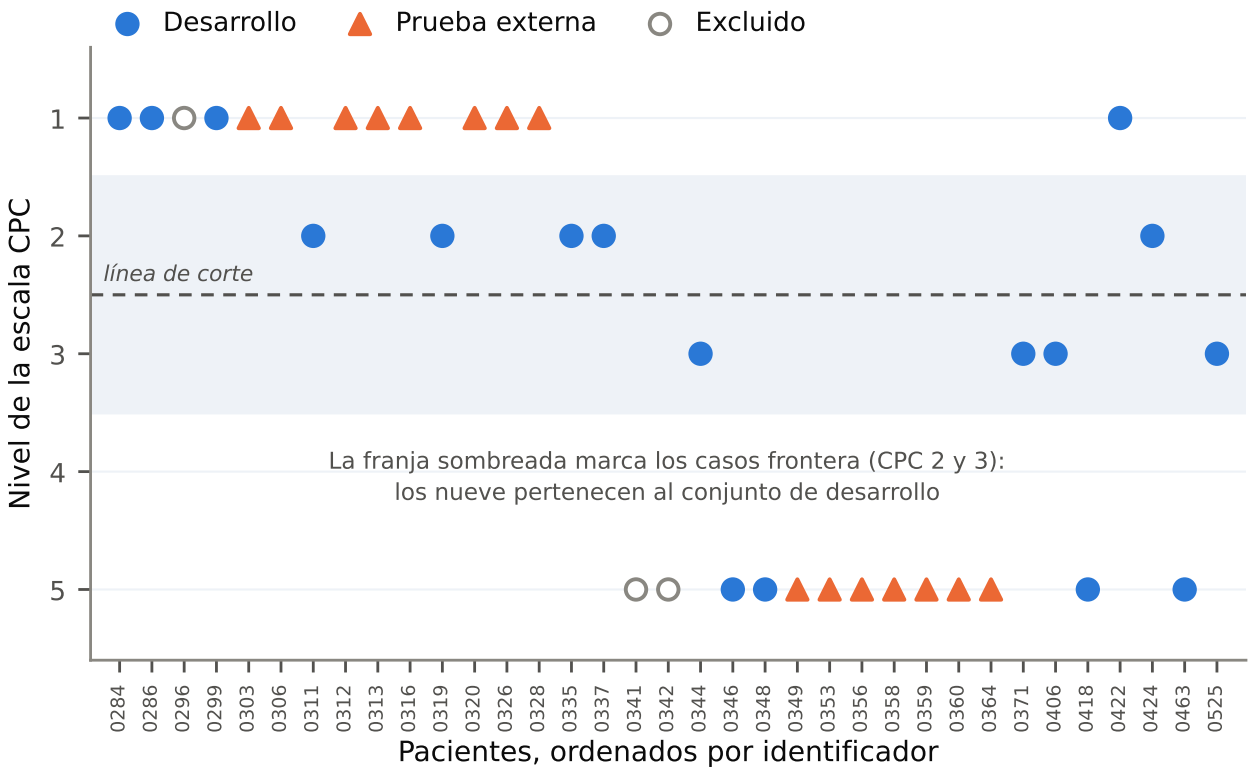


Figura 6.3: Los 35 pacientes descargados, colocados de izquierda a derecha según su identificador y a la altura de su nivel en la escala CPC. La figura permite leer tres cosas. La primera es que los conjuntos de desarrollo y de prueba retenida aparecen entremezclados a lo largo de todo el rango, y no en tramos separados. La segunda es que todos los pacientes situados dentro de la franja sombreada, es decir los que tienen CPC 2 o CPC 3 y son por tanto los casos vecinos a la línea de corte, pertenecen al conjunto de desarrollo. La tercera es que el desenlace aparece agrupado por identificador en estos 35 pacientes, con los favorables concentrados en los identificadores más bajos; se trata de una característica observada en la muestra descargada, cuya causa en la base de datos original no se determinó. La fila correspondiente al CPC 4 está vacía porque ningún paciente de los 35 quedó clasificado en ese nivel.

Tabla 6.1: Los 35 pacientes descargados, ordenados por identificador. La tabla permite comprobar dos afirmaciones del texto. La primera es que los conjuntos de desarrollo y de prueba retenida no ocupan tramos separados de la base de datos, sino que sus identificadores aparecen entremezclados a lo largo de todo el rango. La segunda es que los nueve pacientes cuyo nivel de CPC es 2 o 3, resaltados en negrita y vecinos de la línea de corte entre desenlace favorable y desfavorable, pertenecen todos al conjunto de desarrollo. La última columna indica cuántos segmentos de cada paciente caen dentro de la ventana de 24 a 72 horas; en los tres pacientes excluidos de desarrollo y en el paciente 0356 de prueba retenida ese número es cero. En los demás pacientes de prueba retenida esa cantidad está limitada por la descarga reducida y no por la duración real del registro.

Paciente	Conjunto	Hospital	Edad	Sexo	Desenlace	CPC	Segmentos en ventana
0284	Desarrollo	A	53	H	Favorable	1	59
0286	Desarrollo	F	85	M	Favorable	1	59
0296	Excluido	A	48	H	Favorable	1	0
0299	Desarrollo	A	45	H	Favorable	1	26
0303	Prueba retenida	D	51	H	Favorable	1	43
0306	Prueba retenida	E	73	H	Favorable	1	20
0311	Desarrollo	A	39	M	Favorable	**2**	18
0312	Prueba retenida	D	51	H	Favorable	1	20
0313	Prueba retenida	B	56	H	Favorable	1	20
0316	Prueba retenida	D	41	H	Favorable	1	20
0319	Desarrollo	A	62	H	Favorable	**2**	22
0320	Prueba retenida	F	55	H	Favorable	1	20
0326	Prueba retenida	A	46	H	Favorable	1	20
0328	Prueba retenida	B	56	H	Favorable	1	20
0335	Desarrollo	A	64	H	Favorable	**2**	50
0337	Desarrollo	A	67	M	Favorable	**2**	62
0341	Excluido	A	79	H	Desfavorable	5	0
0342	Excluido	B	71	H	Desfavorable	5	0
0344	Desarrollo	A	50	H	Desfavorable	**3**	61
0346	Desarrollo	E	55	H	Desfavorable	5	15
0348	Desarrollo	E	66	H	Desfavorable	5	51
0349	Prueba retenida	E	78	M	Desfavorable	5	20

Continúa en la página siguiente

Tabla 6.1 (continuación)

Paciente	Conjunto	Hospital	Edad	Sexo	Desenlace	CPC	Segmentos en ventana
0353	Prueba retenida	F	62	M	Desfavorable	5	20
0356	Prueba retenida (excluido)	A	82	M	Desfavorable	5	0
0358	Prueba retenida	E	70	M	Desfavorable	5	20
0359	Prueba retenida	A	80	H	Desfavorable	5	20
0360	Prueba retenida	B	69	H	Desfavorable	5	20
0364	Prueba retenida	B	53	H	Desfavorable	5	5
0371	Desarrollo	A	57	H	Desfavorable	**3**	23
0406	Desarrollo	A	75	H	Desfavorable	**3**	61
0418	Desarrollo	B	82	H	Desfavorable	5	9
0422	Desarrollo	F	42	H	Favorable	1	31
0424	Desarrollo	B	20	H	Favorable	**2**	49
0463	Desarrollo	A	23	M	Desfavorable	5	27
0525	Desarrollo	A	69	H	Desfavorable	**3**	61

El recorrido completo, desde los 35 pacientes descargados hasta los que finalmente se emplearon, se resume en la figura 6.4.

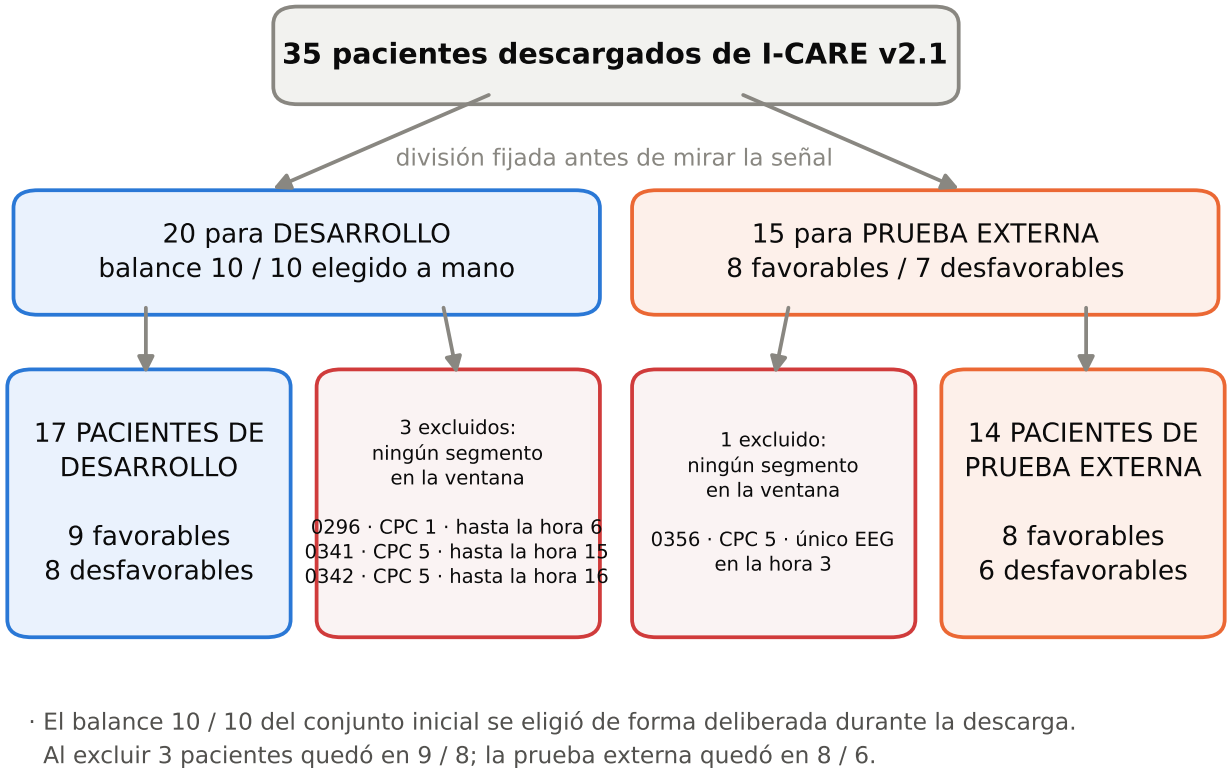


Figura 6.4: Recorrido de la selección de pacientes. De los 35 descargados, 20 se destinaron al desarrollo y 15 se reservaron como conjunto de prueba retenido, división que quedó fijada antes de examinar ninguna señal. Tres de los 20 pacientes de desarrollo se excluyeron después por no disponer de ningún segmento dentro de la ventana de 24 a 72 horas, con lo que el conjunto quedó en 17. Por el mismo motivo se excluyó uno de los 15 pacientes de prueba retenida, que quedó en 14.

De esos 20 pacientes, tres quedaron fuera del conjunto de desarrollo por no contar con ningún registro dentro de la ventana de 24 a 72 horas. Se trata de los pacientes 0296, 0341 y 0342, cuyas grabaciones terminan en las horas 6, 15 y 16 respectivamente, es decir, antes incluso de que la ventana comience. De ellos no era posible extraer una sola época utilizable. Sus datos crudos se conservan sin eliminar, de modo que la exclusión puede rastrearse y repetirse. El conjunto de desarrollo quedó así conformado por 17 pacientes: 9 con desenlace favorable y 8 con desenlace desfavorable.

Por el mismo motivo quedó fuera un paciente del conjunto de prueba retenido, el 0356, cuyo único registro de EEG corresponde a la hora 3 después del paro, antes de que la ventana

comience. El conjunto de prueba retenido quedó así en 14 pacientes: 8 con desenlace favorable y 6 con desenlace desfavorable. En adelante, toda descripción de los dos conjuntos se refiere a los 17 y 14 pacientes efectivamente utilizados.

La figura 6.5 presenta cómo se reparten los niveles de la escala CPC en cada uno de los tres grupos. Conviene mirarla por separado y no de forma agregada, porque al sumar los conjuntos se pierde el hecho más relevante: el conjunto de prueba retenido no contiene ningún paciente con CPC 2 ni con CPC 3, que son precisamente los dos niveles vecinos a la línea de corte y por tanto los casos más difíciles de clasificar. En el conjunto de desarrollo esos casos son 9 de 17.

Esta diferencia no se produjo por casualidad, sino que se explica por la forma en que se eligió cada conjunto. La etiqueta de desenlace agrupa los cinco niveles de la escala CPC en solo dos categorías, de modo que un paciente con CPC 1 y uno con CPC 2 figuran ambos como favorables, y un CPC 3 y un CPC 5 figuran ambos como desfavorables. Al seleccionar el conjunto de prueba retenido mirando únicamente esa etiqueta, los casos vecinos a la línea de corte resultaban indistinguibles de los casos claros, y por eso ninguno llegó a ese conjunto. El conjunto de desarrollo, seleccionado revisando el nivel exacto de la escala, sí los recogió: los nueve pacientes con CPC 2 o CPC 3 de los 35 descargados están todos en él, como puede verse en la tabla 6.1. Conviene precisar el alcance de esta observación. Como solo se descargaron 35 de los 607 pacientes publicados, no es posible afirmar cuántos casos de este tipo quedaron sin seleccionar, y lo único que puede sostenerse es el reparto observado. Las consecuencias de esta diferencia se retoman en los capítulos de resultados y de discusión.

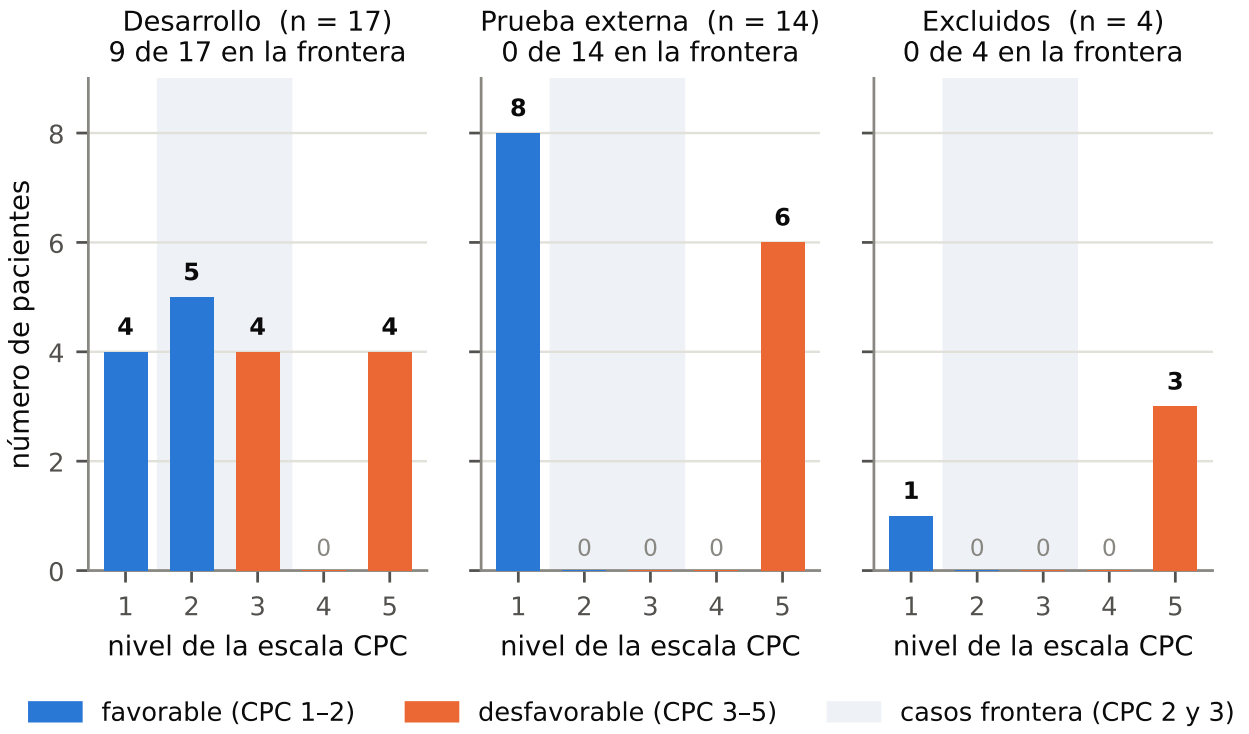


Figura 6.5: Distribución de los niveles de la escala CPC en cada conjunto. La franja sombreada marca los niveles CPC 2 y CPC 3, los vecinos inmediatos de la línea de corte entre desenlace favorable y desfavorable. El conjunto de desarrollo concentra 9 de sus 17 pacientes en esa franja, mientras que el conjunto de prueba retenido no tiene ninguno de sus 14: solo recuperación buena o fallecimiento. El panel de excluidos reúne a los tres pacientes de desarrollo y al 0356 de la prueba retenida, que quedaron fuera por no tener EEG en la ventana de análisis. Ningún paciente de la cohorte quedó clasificado como CPC 4.

Los 17 pacientes del conjunto de desarrollo presentan las siguientes características. Las edades van de los 20 a los 85 años, con un promedio cercano a los 56, y 13 de los 17 son hombres, proporción que refleja la mayor incidencia del paro cardíaco en población masculina. En el conjunto de prueba retenido el promedio de edad es algo mayor, cercano a los 60 años, con una proporción de hombres similar.

Los registros de estos pacientes provienen de cinco hospitales distintos, identificados de forma anónima con las letras A, B, D, E y F. Su reparto no es homogéneo. En el conjunto de desarrollo, 11 de los 17 pacientes pertenecen al hospital A, mientras que los seis restantes se distribuyen entre los hospitales B, E y F, con dos pacientes cada uno. En el conjunto de prueba retenido la composición es distinta: solo 2 de los 14 pacientes provienen del hospital A, y aparecen tres pacientes del hospital D, un centro que no está representado en el conjunto de desarrollo. Esto

significa que el modelo se evaluó en parte sobre registros procedentes de un hospital cuyos datos nunca vio durante el entrenamiento, una circunstancia que se analiza en el capítulo de discusión.

Ninguna de estas dos diferencias fue buscada. El campo que indica el hospital de procedencia no se consultó en ningún momento al seleccionar los pacientes, ni para el conjunto de desarrollo ni para el de prueba, y el reparto por centros se descubrió mucho después, al explorar los datos ya descargados. Se trata por tanto de un efecto no intencionado de haber elegido a mano los pacientes de desarrollo. La tabla 6.1 permite verlo: en un mismo tramo de identificadores conviven pacientes de los dos conjuntos, y aun así la mayoría de los que fueron elegidos a mano procede del hospital A, mientras que entre los que se tomaron sin consultar sus datos clínicos aparecen centros mucho más variados. La diferencia proviene entonces del modo de selección y no del orden en que los registros están almacenados.

La figura 6.6 reúne estas tres características para los dos conjuntos.

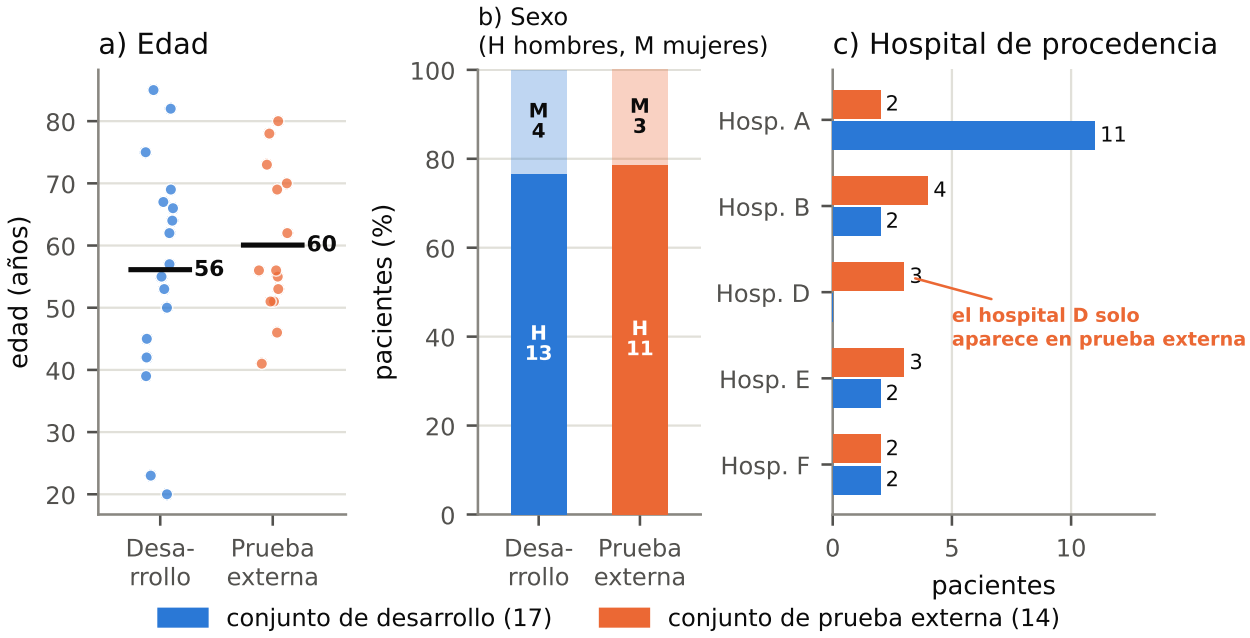


Figura 6.6: Caracterización de los pacientes por conjunto. a) Edad de cada paciente, con la media señalada por la línea horizontal. b) Sexo: mayoría de hombres en los dos conjuntos (13 de 17 y 11 de 14), con 4 y 3 mujeres respectivamente. c) Hospital de procedencia. Se aprecian dos diferencias de composición: el conjunto de desarrollo está dominado por el hospital A, y los tres pacientes del hospital D aparecen únicamente en el conjunto de prueba retenido, de modo que el modelo se evaluó en parte sobre un centro cuyos registros nunca vio durante el entrenamiento.

Cada paciente cuenta además con información clínica básica registrada al ingreso: edad, sexo, si el paro ocurrió dentro o fuera del hospital, si el ritmo cardíaco inicial era desfibrilable y la temperatura objetivo del manejo térmico aplicado. Dos de estos datos merecen una aclaración. Que el ritmo inicial sea *desfibrilable* quiere decir que el corazón se detuvo de una forma que puede corregirse con una descarga eléctrica, como las que aplica un desfibrilador; cuando no es así, la descarga no sirve y la reanimación depende de otras maniobras. La *temperatura objetivo*, por su parte, es la temperatura a la que se enfrió al paciente después del paro para proteger su cerebro. Algunos de estos campos están ausentes en parte de los pacientes, lo cual se tuvo en cuenta al utilizarlos como referencia clínica de comparación.

La figura 6.7 muestra hasta qué hora llega la grabación de cada paciente y permite ver de un vistazo por qué tres de ellos quedaron fuera.

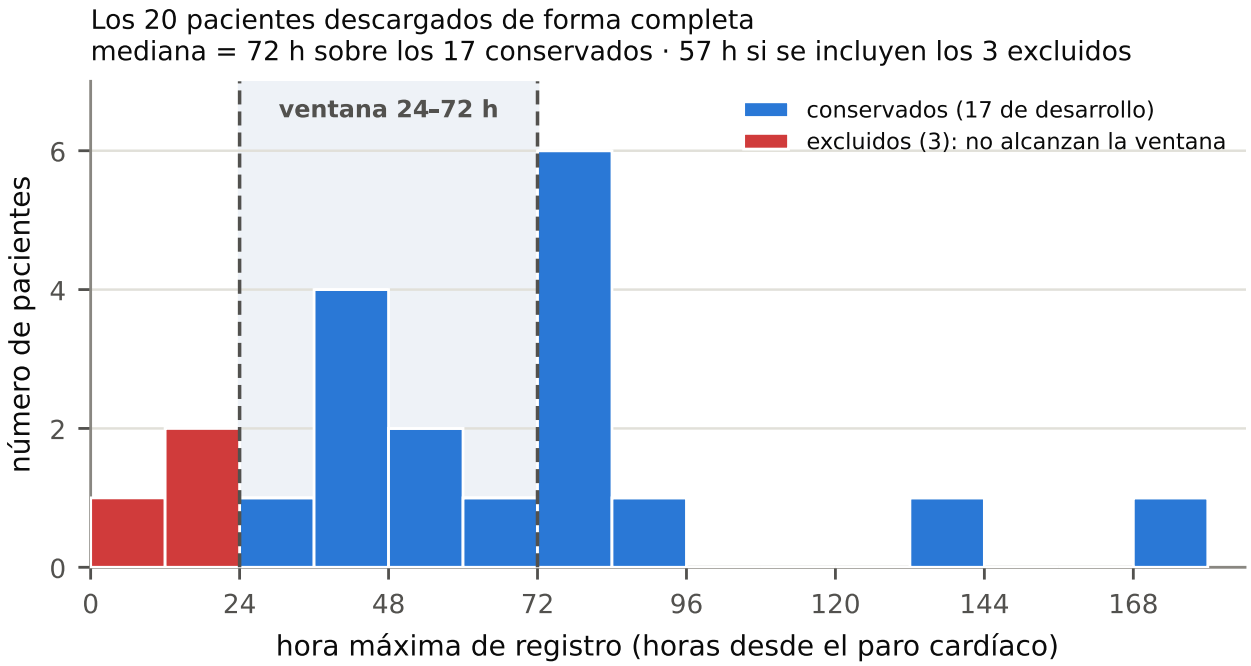


Figura 6.7: Hora hasta la que se extiende la grabación de cada paciente. Los tres pacientes marcados en rojo terminan antes de que la ventana comience, y son exactamente los que se excluyeron. La figura recoge únicamente a los 20 pacientes descargados de forma completa: los 15 del conjunto de prueba retenido se descargaron de manera reducida, tomando solo segmentos dentro de la ventana, de modo que su hora máxima está limitada por la descarga y no por el paciente, e incluirlos daría una impresión equivocada.

Conviene matizar por último qué significa que un paciente esté dentro de la ventana, porque estar dentro no equivale a cubrirla por completo. Al revisar el rango horario de cada registro se

observó que la cobertura varía considerablemente entre pacientes: algunos disponen de grabación a lo largo de casi todo el rango, mientras que otros aportan solo un tramo. Un paciente comienza a grabar en la hora 46, de modo que cubre únicamente las últimas 18 horas de la ventana, y otro termina en la hora 32, cubriendo apenas las primeras 9. Dado que el estado neurológico evoluciona a lo largo de esas 48 horas, esto implica que no todos los pacientes se observan en el mismo momento de su recuperación, una fuente de variabilidad que se retoma en el capítulo de limitaciones. La figura 6.8 representa esta cobertura paciente por paciente.

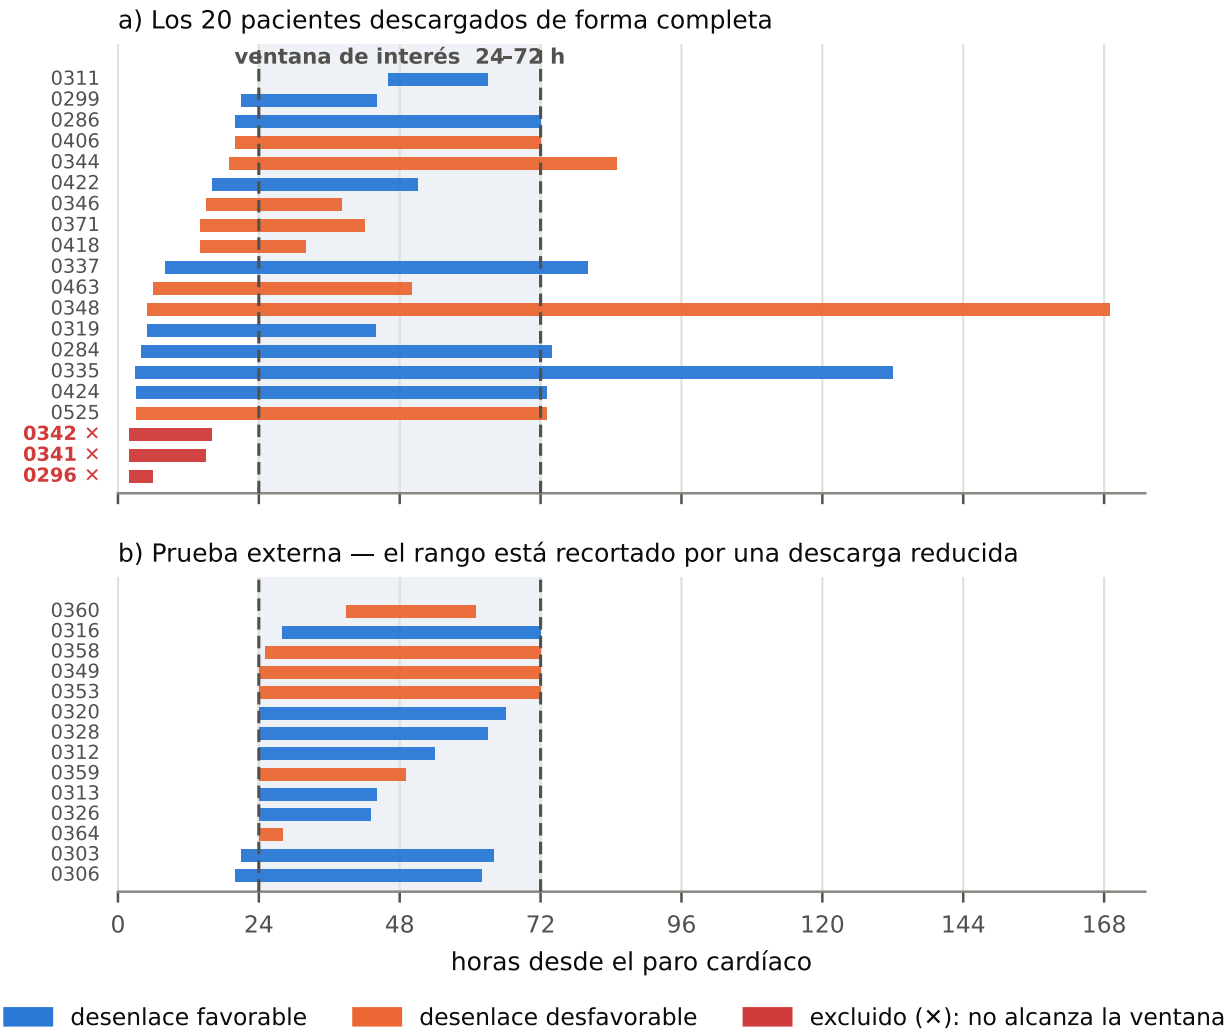


Figura 6.8: Tramo horario cubierto por la grabación de cada paciente, desde su primer segmento hasta el último, sobre la ventana de interés sombreada al fondo. a) Los 20 pacientes descargados de forma completa; los tres marcados con un aspa terminan antes de la hora 24 y por eso no aportan ninguna época. Se observa que estar dentro de la ventana no equivale a cubrirla: hay pacientes que solo alcanzan un tramo. b) El conjunto de prueba retenido se presenta aparte porque su descarga reducida recorta el rango de forma artificial, y compararlo con el panel superior llevaría a conclusiones equivocadas. Este panel contiene 14 pacientes, porque el 0356 no tiene ningún segmento dentro de la ventana.

6.2.2 Preprocesamiento y Limpieza de Señales

Antes de poder analizar la señal de EEG, esta debe pasar por un proceso de limpieza y estandarización, necesario porque los registros crudos de I-CARE presentan formatos y condiciones heterogéneas entre pacientes (distintas frecuencias de muestreo y distinta cantidad de canales disponibles). El pipeline de preprocesamiento desarrollado sigue los siguientes pasos, en este orden:

1. **Selección de canales:** se seleccionan 19 canales estándar del sistema internacional 10-20 de colocación de electrodos, en un orden fijo e idéntico para todos los pacientes, de modo que la misma posición de electrodo represente siempre la misma columna de datos entre distintos sujetos (Figura 6.9). El número de canales de EEG varía entre registros: en los 34 pacientes descargados que tienen EEG, los 19 canales elegidos aparecen en todos, mientras que los adicionales aparecen solo en algunos (Fpz en 17 y F9 en 4). Los 19 son, por tanto, el núcleo común a todos los pacientes. El programa se detiene con un error si a un segmento le falta alguno de ellos, y ninguno de los segmentos procesados lo provocó.

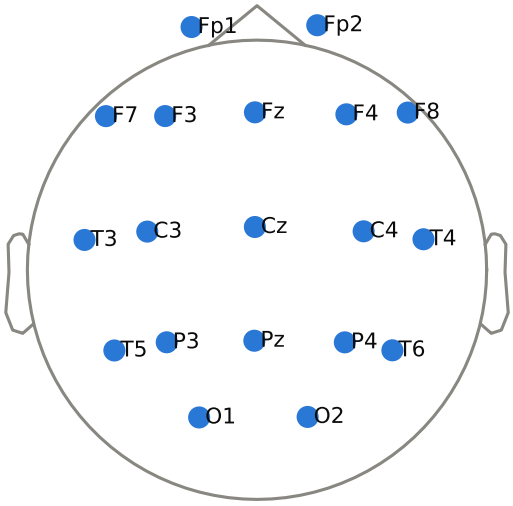


Figura 6.9: Posición sobre el cuero cabelludo de los 19 canales utilizados, según el sistema internacional 10-20, visto desde arriba con la nariz hacia la parte superior. Se conserva la nomenclatura de I-CARE (T3, T4, T5 y T6).

2. **Filtrado de frecuencia:** se aplica un filtro de tipo *notch* (para eliminar la interferencia de la red eléctrica local) y un filtro pasa-banda entre 0,5 y 45 Hz, que conserva únicamente el rango de frecuencias fisiológicamente relevante para la actividad cerebral (Bigdely-Shamlo et al., 2015). Ambos filtros se explican en la Sección 5.2.2.
3. **Remuestreo:** los registros de I-CARE vienen grabados con distintas frecuencias de muestreo según el hospital y el equipo, y para que todos tengan el mismo formato se llevan a una frecuencia común de 100 Hz, es decir, 100 mediciones por segundo. A esa frecuencia, el

límite de Nyquist es de 50 Hz, por encima de los 45 Hz que deja pasar el filtro, así que no queda ninguna onda capaz de disfrazarse. Por eso este paso se aplica después del filtrado y nunca antes (Sección 5.2.2).

4. **Referencia promedio común (CAR):** la señal de cada canal se re-referencia respecto al promedio de todos los canales disponibles, un procedimiento estándar que reduce el ruido común a todos los electrodos. Esto es especialmente relevante en una unidad de cuidados intensivos, donde el paciente está rodeado de equipos que introducen interferencias que afectan a todos los canales por igual; al restar el promedio, esa componente compartida desaparece y queda resaltada la actividad propia de cada posición. Antes de calcular ese promedio, en cada segmento se identifican los canales que no registran señal, porque su desviación estándar cae por debajo de una milésima de la mediana de los demás, y se excluyen del cálculo (Sección 5.2.2). Esta precaución no formaba parte del diseño inicial y se añadió para corregir un problema concreto. Un electrodo desconectado registra una línea plana, en cero. En la versión inicial ese canal entraba al promedio como cualquier otro, y al restarle el promedio dejaba de estar en cero: pasaba a mostrar, invertida, la actividad común del resto de los canales. Con el ejemplo de la Sección 5.2.2, un micrófono apagado graba silencio, pero si a su pista se le resta lo que todos tienen en común, pasa a contener ese zumbido y ya no parece apagado. Como el rechazo del paso 6 identifica los electrodos desconectados precisamente porque se ven planos, ese canal dejaba de ser detectable.

   El problema se encontró al revisar el código del preprocesamiento, analizando en qué orden se aplicaban el promedio común y el rechazo de épocas. Antes de aplicar la corrección a los datos reales, se comprobó con una señal artificial, con un canal fijado en cero, que ese canal permanecía plano tras el promedio común y que el paso 6 lo detectaba. Después se volvieron a procesar los 17 pacientes de desarrollo: en 16 de ellos el resultado no cambió, y en el paciente 0463, 262 épocas que antes pasaban como limpias se identificaron y descartaron como planas. Cada paciente conservó sus 2000 épocas.

La corrección cubre los electrodos que dejan de registrar, pero no los que registran ruido excesivo: un canal así entra en el promedio y reparte su ruido entre los demás. Tampoco se detectan los artefactos que afectan solo a dos o tres canales, porque el criterio del paso 6 resume cada época con la mediana de todos ellos. Ambos aspectos se recogen entre las limitaciones del trabajo.

5. **División en épocas:** la señal continua se divide en tramos de duración fija de 10 segundos, denominados épocas, que son la unidad básica sobre la cual se extraen características más adelante. La duración de 10 segundos responde a un compromiso: es lo bastante corta para que las propiedades de la señal puedan considerarse estables dentro de cada época, y lo bastante larga para estimar de forma confiable el contenido de las frecuencias más bajas, como la banda delta. Además, al dividir un registro largo en muchas épocas se obtiene un número de muestras suficiente para entrenar el modelo.
6. **Rechazo de épocas ruidosas:** se descartan automáticamente las épocas que presentan comportamientos anómalos (tramos completamente planos, que suelen indicar un electrodo desconectado, o amplitudes estadísticamente extremas respecto al resto del registro), aplicando un criterio relativo basado en desviaciones estadísticas dentro de cada registro, en lugar de un umbral fijo, dado que las señales de I-CARE no están calibradas en unidades físicas estándar. Concretamente, para cada época se calcula una amplitud representativa, la mediana entre los 19 canales de la variabilidad de cada uno, y se compara con la de las demás épocas del mismo paciente mediante una puntuación z robusta (Sección 5.2.2). La época se descarta si se aleja más de 4 unidades del centro, sea por exceso o por defecto, o si alguno de sus canales aparece plano.

Para efectos de reproducibilidad, los parámetros concretos son los siguientes. El filtrado se realizó con la biblioteca MNE-Python (versión 1.11), empleando filtros de respuesta finita al impulso y fase cero, cuya longitud la propia biblioteca determina a partir del ancho de la banda de transición; se conservaron sus valores por defecto, de modo que el procedimiento queda reproducible indicando la versión utilizada. La frecuencia del filtro notch no se fijó de antemano: se lee del

encabezado de cada paciente, ya que los registros de I-CARE provienen de hospitales con redes eléctricas de 50 y de 60 Hz, y se eliminan también sus armónicos hasta la frecuencia de Nyquist. El pasa-banda se aplicó entre 0,5 y 45 Hz, el remuestreo a 100 Hz, la duración de época en 10 segundos y el rechazo de épocas con un umbral de z robusto de 4,0, considerando plano todo canal cuya desviación estándar cayera por debajo de una milésima de la mediana del registro.

Cuánta señal se utiliza de cada paciente. Queda por describir una decisión que afecta a la cantidad de señal que finalmente se utiliza. El procedimiento descrito no se aplica a todos los segmentos disponibles dentro de la ventana, ni conserva todas las épocas que se obtienen de ellos.

El procedimiento es el siguiente. Antes de procesar nada, el programa calcula cuántos segmentos necesita para reunir el número de épocas que va a conservar. Ese cálculo parte de tres valores fijos: el máximo de épocas por paciente, establecido en 2000; una estimación de cuántas épocas produce un segmento, fijada en 250, que corresponde a unos 42 minutos de grabación, una cifra deliberadamente conservadora frente a los cerca de 47 minutos que contiene en promedio un segmento del paciente 0284; y un factor de seguridad de 2, que duplica la cantidad para compensar los segmentos más cortos de lo habitual y las épocas que después serán descartadas por ruido. El número de segmentos a procesar es el resultado de multiplicar el máximo de épocas por el factor de seguridad y dividirlo entre la estimación por segmento, redondeando hacia arriba, sin superar nunca la cantidad de segmentos realmente disponibles.

Aplicado al paciente 0284, que dispone de 59 segmentos dentro de la ventana, el cálculo da 16 segmentos. Esos 16 no son los primeros de la lista: el programa genera 16 posiciones repartidas uniformemente entre el primer y el último segmento disponible (con la función `linspace` de NumPy, redondeando cada posición al segmento más cercano) y toma los que caen en ellas. En el paciente 0284 resultan los segmentos 1, 5, 9, 13, 16, 20, 24, 28, 32, 36, 40, 44, 47, 51, 55 y 59, es decir, uno de cada tres o cuatro, desde el primero hasta el último (Figura 6.10a), de manera que la selección queda distribuida a lo largo de todo el rango. El mismo criterio se aplica después a las épocas: de todas las que sobreviven a la limpieza se conservan 2000, escogidas igualmente en posiciones equiespaciadas.

La reducción es considerable y conviene dimensionarla (Figura 6.10b). Los 59 segmentos de este paciente suman 45,8 horas de señal dentro de la ventana, que permiten cortar 16 479 épocas completas de diez segundos. Los 16 segmentos procesados aportan 4238 épocas, de las cuales 4141 superan la limpieza del paso 6, y de ellas se conservan 2000, es decir, alrededor del 12 % de la señal disponible, equivalentes a unas 5,6 horas repartidas por todo el rango. La etapa de modelado aplica después una reducción más, con el mismo criterio de posiciones equiespaciadas, y entrena con 200 de esas 2000 épocas (Sección 6.2.4): al modelo llega el 1,2 % de la señal disponible, unos 33 minutos de cada paciente.

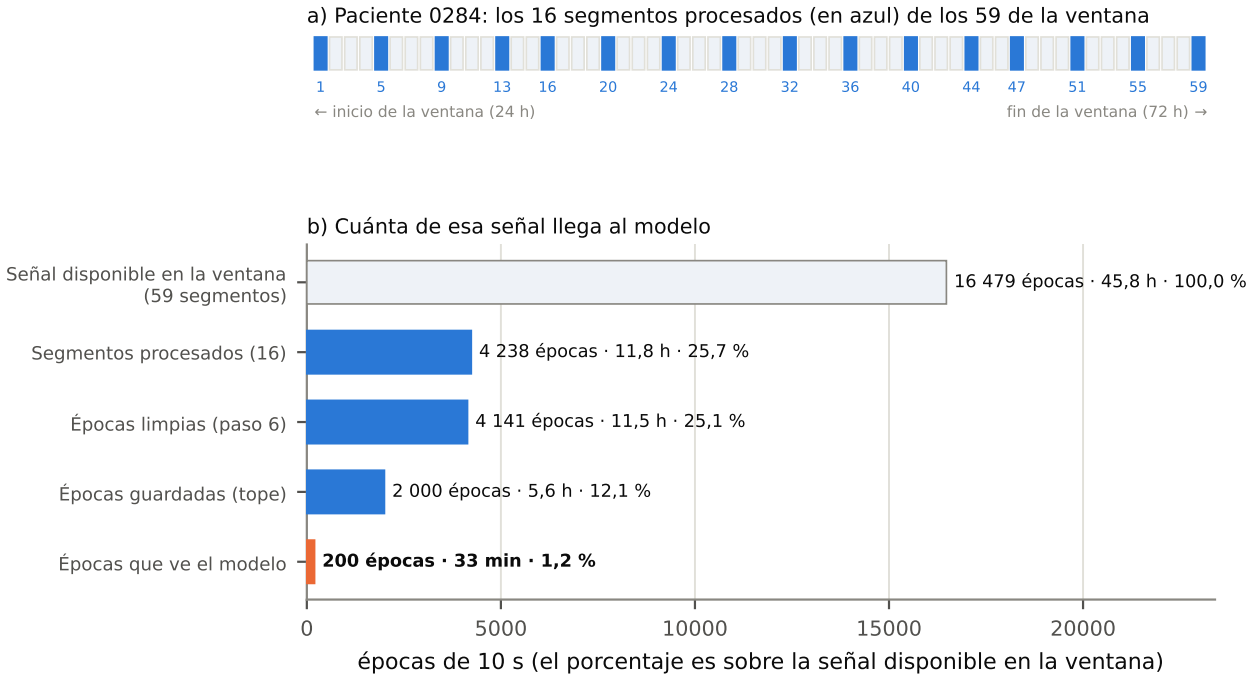


Figura 6.10: Cuánta señal del paciente 0284 llega al modelo. a) Sus 59 segmentos dentro de la ventana, ordenados de la hora 24 a la 72, con los 16 que se procesan en azul; la tira ordena archivos y no horas de reloj, porque un segmento no siempre dura una hora. b) Cada reducción expresada en épocas de diez segundos, con su duración y su porcentaje sobre la señal disponible. Las cifras de los demás pacientes varían, porque cada uno tiene un número distinto de segmentos en la ventana, pero los 17 terminan con las mismas 2000 épocas guardadas y las mismas 200 para el modelo.

Esta decisión responde a dos motivos, y el segundo resulta el más relevante. El primero es que iguala el peso de cada paciente dentro del entrenamiento: sin un tope, un paciente con 48 horas de grabación aportaría alrededor de cuatro veces más épocas que uno con 12 horas, y el modelo quedaría dominado por los sujetos con registros más extensos. El segundo motivo es que la duración

de la grabación no es independiente del desenlace. La documentación de I-CARE señala que la duración media del registro varía de forma apreciable según el resultado neurológico, desde unas 53 horas en los pacientes con mejor pronóstico hasta unas 102 horas en los de peor pronóstico (Amorim et al., 2023), lo cual resulta esperable si se considera que a un paciente que no evoluciona favorablemente se le mantiene monitorizado durante más tiempo. Sin un límite por paciente, la cantidad de datos disponible sería en sí misma una pista sobre el desenlace, y el modelo podría aprender a apoyarse en esa pista en lugar de analizar la señal. Fijar un mismo número de épocas para todos los pacientes elimina esa posibilidad.

Tanto los segmentos como las épocas se escogen espaciados y no consecutivos por una razón adicional: el estado neurológico del paciente cambia a lo largo de la ventana, de modo que tomar los primeros segmentos ofrecería una imagen únicamente del inicio del período, mientras que el muestreo espaciado conserva la cobertura de todo el rango.

Tras aplicar este procedimiento sobre los 17 pacientes del conjunto de desarrollo, se obtuvo un conjunto final de épocas limpias, listo para la fase de extracción de características descrita en la siguiente sección.

La Figura 6.11 resume el recorrido completo de la señal de un paciente, desde sus archivos de EEG crudo hasta el pronóstico. El tramo azul corresponde al preprocesamiento descrito en esta sección; los tramos siguientes, a la extracción de características y al modelo, que se describen en las secciones posteriores.

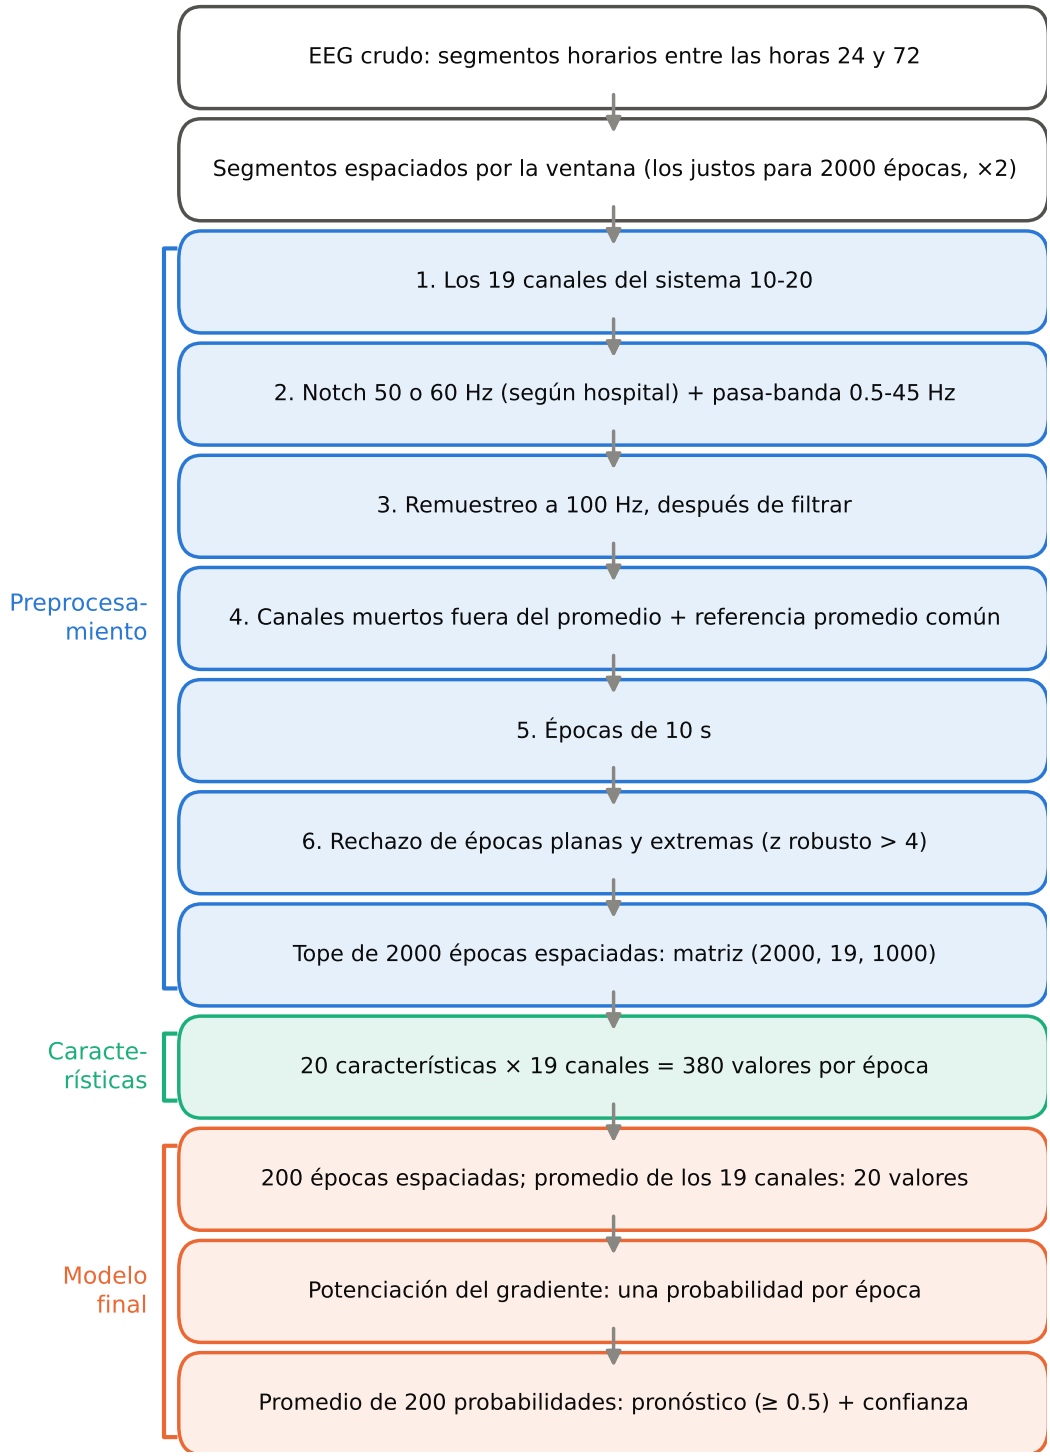


Figura 6.11: Recorrido completo de la señal de un paciente, con los parámetros empleados. Los pasos 1 a 5 se aplican a cada segmento por separado; después se unen las épocas de todos los segmentos, se rechazan las ruidosas y se conservan 2000 repartidas por toda la ventana. Cada época se resume en 380 valores, y el modelo final trabaja con 200 épocas por paciente y con el promedio de los 19 canales.

6.2.3 Ingeniería de Características (Feature Engineering)

Cada época de 10 segundos se resume en un conjunto de **20 características**, calculadas por separado en cada uno de los 19 canales. Así, cada época queda convertida en una fila de **380 valores** (20×19). En esta etapa los canales se conservan por separado, sin promediarlos. La forma de combinarlos antes de entrenar se decidió en la etapa de modelado (Sección 6.2.4), donde se compararon varias alternativas; el modelo final promedia cada característica sobre los 19 canales. Con 17 pacientes y 2000 épocas por paciente, la tabla resultante tiene **34 000 filas por 380 columnas**, sin ningún valor faltante ni infinito.

Las 20 características se agrupan en cinco familias (Tabla 6.2). Qué mide cada una y a cuál de los tres cambios del EEG tras el paro responde se definió en la Sección 5.2.5; aquí se describe cómo se calcularon. Las características espectrales parten de un espectro de potencia estimado con el método de Welch (Welch, 1967): la época de 10 segundos (1000 muestras) se recorre con sub-ventanas de 256 muestras (2,56 segundos) que se solapan a la mitad, se calcula el espectro de cada sub-ventana y se promedian. Promediar varios espectros cortos, en lugar de calcular uno solo sobre toda la época, reduce el ruido de la estimación, y la resolución resultante, de $100/256 \approx 0{,}39$ Hz, basta para separar las cinco bandas.

Tabla 6.2: Las 20 características extraídas de cada época, agrupadas en cinco familias. Cada una se calcula en los 19 canales, lo que da 380 columnas por época. SEF95 y SEF50 son las frecuencias por debajo de las cuales se acumula el 95 % y el 50 % de la energía del espectro.

Familia	Características	Qué mide
Potencia relativa (5)	δ, θ, α, β, γ	Fracción de la energía total que cae en cada banda
Cocientes entre bandas (4)	α/δ, θ/α, α/θ, $(\delta+\theta)/(\alpha+\beta)$	Enlentecimiento del espectro
Forma del espectro (4)	Entropía espectral, SEF95, SEF50, centroide espectral	Dónde se concentra la energía y qué tan repartida está
Dominio del tiempo (5)	Movilidad y complejidad de Hjorth, longitud de línea normalizada, tasa de cruces por cero, curtosis	Forma de la onda y presencia de ráfagas
Complejidad y asimetría (2)	Entropía de permutación, asimetría estadística (*skewness*)	Qué tan predecible es el orden de la señal y si su distribución de amplitudes se carga hacia un lado

Invariancia a escala, comprobada y no solo supuesta. Todas las características cumplen que el resultado no cambia si la señal se multiplica por un factor, por la razón explicada en el Capítulo 5. Esto se comprobó de forma empírica: se tomaron épocas reales, se multiplicaron por factores entre 10^3 y 10^{-8} y se recalcularon las 20 características. La mayor diferencia observada fue del orden de 10^{-10}, que corresponde al redondeo numérico del computador y no a un cambio real. Se usaron factores tan extremos a propósito: con factores moderados ($\times 10$, $\times 0{,}1$), una primera versión del cálculo pasaba la prueba a pesar de tener una dependencia oculta de la escala.

Decisiones de diseño. Dos decisiones merecen declararse. Primero, de los tres parámetros de Hjorth se excluyó la *actividad*, porque es la varianza de la señal y crece con su amplitud, así que habría introducido justo el sesgo de calibración que se quería evitar. Segundo, se incluyeron tanto θ/α como su inverso α/θ: contienen la misma información, pero un modelo lineal no reconoce esa relación, y según la distribución de los datos uno de los dos puede separar mejor las clases.

Por último, esta etapa **no puede introducir fuga de información entre pacientes**: cada época se calcula de forma independiente, sin ningún parámetro aprendido de los datos. Además, el cálculo se detiene con un error si detecta un archivo del conjunto de prueba retenido entre los de desarrollo, una protección que se añadió después de que un paciente de ese conjunto se colara una vez por error en la carpeta de trabajo.

6.2.4 Modelado Computacional

El modelado parte de la matriz de 380 columnas descrita en la sección anterior y aplica, antes de cualquier algoritmo, dos reducciones que conviene declarar, porque cambian lo que el modelo finalmente recibe.

Una precisión de vocabulario. En este trabajo, *época* designa siempre una ventana de 10 segundos de señal (Sección 6.2.2) y no una pasada completa del algoritmo sobre los datos de entrenamiento, que es el sentido que tiene el término en las redes neuronales. Ninguno de los algoritmos evaluados se entrena por épocas en ese segundo sentido.

Primera reducción: 200 épocas por paciente. De las 2000 épocas disponibles por paciente se utilizan 200, tomadas a intervalos regulares a lo largo de toda la secuencia, de modo que sigan cubriendo la ventana de 24 a 72 horas completa y no solo su comienzo. La selección no es aleatoria: la misma entrada produce siempre las mismas 200 épocas, lo que hace reproducible todo el experimento. Con 17 pacientes, el conjunto de entrenamiento queda en **3400 filas**. La razón de esta reducción es el costo computacional: permite repetir cientos de entrenamientos en segundos. Se comprobó que no altera el resultado: en la exploración inicial se entrenaron los mismos modelos con 50, 200, 500 y 2000 épocas (ventanas de señal) por paciente, y el AUC medio sobre todas las configuraciones del barrido fue 0,41, 0,40, 0,44 y 0,46 respectivamente, diferencias que quedan dentro de la variación esperable por azar con 17 pacientes.

Segunda reducción: promedio de los 19 canales. Cada una de las 20 características se promedia sobre los 19 canales, de modo que cada época pasa de 380 valores a **20**. La razón es que los canales no aportan 19 informaciones independientes: en 18 de las 20 características, la correlación mediana entre pares de canales supera 0,5, con una mediana general de 0,76. Con solo 17 pacientes, reducir el número de columnas disminuye el riesgo de que el modelo se ajuste a las particularidades de cada paciente en lugar de a lo que distingue a las dos clases. Ese riesgo no es teórico. Se entrenó una regresión logística con 17 clases posibles, una por paciente, usando las 380 columnas del 70 % de las épocas, y se le pidió identificar a qué paciente pertenecía cada una de las 1020 épocas restantes, que no había visto. Acertó en el 98,3 % de ellas, cuando eligiendo al azar entre 17 pacientes acertaría en el 5,9 %. Cada paciente deja en sus características una huella individual muy marcada, que compite con la señal clínica que se busca. Tras promediar los canales, la tasa baja al 71,0 %, todavía doce veces el azar: el promedio reduce esa huella, pero no la elimina. La reducción tiene un costo que también se declara: se pierde toda la información sobre dónde ocurre cada fenómeno en el cuero cabelludo. Para un daño cerebral que tras un paro cardíaco suele ser difuso, es una pérdida aceptable en una primera versión, pero no lo sería para detectar lesiones localizadas. Además, en una de las características, la asimetría, la correlación entre canales es prácticamente nula, de modo que en ella el promedio sí borra información.

Algoritmos evaluados. Sobre esos datos se evaluaron las cuatro familias descritas en la Sección 5.3.2: regresión logística, máquinas de vectores de soporte, bosques aleatorios y potenciación del gradiente, con varias configuraciones de cada una. La regularización, que es el mecanismo que limita qué tanto se ajusta un modelo a sus datos de entrenamiento, se fijó deliberadamente en valores fuertes, porque con 17 pacientes el riesgo dominante es el sobreajuste. A la lista se añadió un clasificador trivial, que ignora las características y predice siempre según la proporción de clases del entrenamiento. No es un candidato real sino un *suelo*: un modelo que no lo supere no aporta nada.

El flujo de entrenamiento. Cada candidato se organizó como una única cadena de pasos (un `Pipeline` de la biblioteca scikit-learn): promedio de canales, estandarización de las columnas y clasificador. La estandarización resta a cada columna su media y la divide por su desviación típica, y esas dos cantidades se calculan a partir de los datos. Si se calcularan con todos los pacientes antes de separar entrenamiento y prueba, el paciente de prueba influiría en su propia transformación, una fuga de información sutil y difícil de detectar después. Al estar dentro de la cadena, se calculan cada vez solo con los pacientes de entrenamiento.

El modelo final. El procedimiento de selección, descrito en la sección siguiente, eligió un clasificador de **potenciación del gradiente** con árboles de profundidad máxima 3, 200 iteraciones (200 árboles añadidos uno tras otro; la coincidencia con las 200 épocas por paciente es casual) y tasa de aprendizaje 0,1 (`HistGradientBoostingClassifier`). Una vez elegido, se volvió a entrenar con los 17 pacientes de desarrollo (3400 filas) y se **congeló**: se guardó junto con una ficha que fija qué columnas recibe, en qué orden, cómo combina las épocas y con qué umbral decide, de modo que su aplicación posterior al conjunto de prueba retenido no admitiera ninguna interpretación. Para pronosticar a un paciente, el modelo calcula una probabilidad de desenlace favorable para cada una de sus 200 épocas; la probabilidad del paciente es el **promedio** de esas 200, y el pronóstico es favorable cuando ese promedio es igual o mayor que 0,5. Ese promedio es, a la vez, la confianza que acompaña al pronóstico.

6.2.5 Validación y Evaluación

La unidad de evaluación es el paciente. Aunque el modelo se entrena con épocas, todas las métricas se calculan a nivel de paciente: primero se promedian las probabilidades de las épocas de cada paciente y después se compara ese pronóstico con su desenlace real. Evaluar época por época contaría 3400 aciertos o errores donde en realidad solo hay 17 decisiones independientes, y daría una falsa sensación de precisión. Por la misma razón, los intervalos de confianza se calcularon remuestreando *pacientes*, no épocas, con 2000 repeticiones.

Validación cruzada dejando un paciente fuera. Con 17 pacientes no es posible reservar un grupo fijo de validación sin quedarse casi sin datos de entrenamiento. Se usó por eso la validación cruzada *dejando un paciente fuera* (LOPO, del inglés *Leave-One-Patient-Out*). Es la variante agrupada de la validación cruzada dejando uno fuera (LOOCV, *Leave-One-Out Cross-Validation*). En la LOOCV clásica se deja fuera una sola muestra, que aquí sería una época, y las demás épocas del mismo paciente quedarían en el entrenamiento: es exactamente la fuga de información que este diseño evita. En LOPO se deja fuera el paciente completo: el modelo se entrena con 16 pacientes, se evalúa sobre el que quedó fuera, y el proceso se repite 17 veces, hasta que cada paciente ha sido evaluado exactamente una vez por un modelo que nunca vio ninguna de sus épocas. El código comprueba de forma explícita, en cada una de las 17 particiones, que ningún paciente aparece a la vez en entrenamiento y en prueba, y se detiene con un error si ocurre.

Validación cruzada anidada. Elegir el mejor de varios modelos mirando su resultado en la validación cruzada y reportar después ese mismo resultado lo infla: es quedarse con el máximo de una lista de números con ruido. Para evitarlo, la elección se hizo *dentro* de cada una de las 17 particiones. En cada una, los 16 pacientes de entrenamiento se dividieron a su vez en cuatro grupos, siempre respetando que un paciente no se reparta entre grupos, y con ellos se eligió el candidato con mayor AUC a nivel de paciente en esas cuatro particiones internas; solo entonces ese candidato se entrenó con los 16 y se evaluó sobre el paciente excluido, que no participó en la elección. Entraron en esta selección cinco candidatos de tres familias (tres regresiones logísticas

con distinta regularización, un bosque aleatorio y un clasificador de potenciación del gradiente) más el clasificador trivial. Las máquinas de vectores de soporte se evaluaron en la exploración previa, pero no formaron parte de esta lista.

Lo que la validación anidada no protege. La selección anidada protegió la elección del algoritmo, pero no las dos reducciones de la sección anterior: el número de épocas y el promedio de canales se fijaron antes, y fuera de ella, después de una exploración de 84 configuraciones sobre los mismos 17 pacientes. Ambas decisiones tienen una justificación previa, independiente del resultado (el costo de cómputo y la correlación entre canales), y la configuración elegida no es la que mejor resultado obtuvo en esa exploración, que fue la de 500 épocas por paciente. Aun así, es una decisión tomada sobre los mismos datos con los que después se midió, y por eso se declara. La garantía definitiva frente a ella es el conjunto de prueba retenido, que no participó en ninguna de estas decisiones. Por eso la exploración de 84 configuraciones se reporta como análisis exploratorio, y solo dos estimaciones tienen carácter confirmatorio: la de la validación anidada, condicionada a esas dos decisiones previas, y la del conjunto retenido, que no intervino en ninguna.

Cuál es el azar en cada protocolo. Un AUC de 0,5 corresponde a un modelo que ordena a los pacientes al azar, pero solo cuando el modelo no cambia de una evaluación a otra. En la validación dejando un paciente fuera sí cambia, y eso desplaza el azar hacia abajo. Al sacar a un paciente con desenlace favorable, el entrenamiento queda con 8 favorables y 8 desfavorables; al sacar a uno desfavorable, queda con 9 y 7. Cada vez que se excluye a un paciente, el entrenamiento queda inclinado hacia la clase *contraria* a la suya, y esa inclinación empuja el AUC por debajo de 0,5 sin que el modelo haya aprendido nada. El caso extremo es el clasificador trivial, que en este protocolo obtiene un AUC de exactamente 0: ordena a todos los pacientes al revés. Por eso el azar de este protocolo no se supuso, sino que se **midió**: se barajaron las etiquetas entre pacientes 100 veces, conservando la proporción de 9 y 8, y se repitió la validación completa cada vez. La unidad que se permuta es el paciente, no la época: cada paciente conserva todas sus épocas y recibe la etiqueta de otro. El valor p es $(b + 1)/(m + 1)$, donde b es el número de permutaciones con un

AUC igual o mayor que el observado y $m = 100$; con 17 de 100 resulta $18/101 = 0{,}178$. Sumar uno evita reportar un p igual a cero, y cien permutaciones bastan para decidir frente a 0,05, aunque el menor valor alcanzable sea 1/101. El azar resultante tiene una media de **0,388** y una desviación típica de 0,171, y el resultado del modelo se compara con esa distribución, no con 0,5.

En el conjunto de prueba retenido la situación es la contraria. El modelo ya está congelado y no se vuelve a entrenar, de modo que sus probabilidades no cambian, y ahí el azar sí está centrado en **0,5**. Con 14 pacientes, de los cuales 8 tuvieron desenlace favorable, existen exactamente 3003 formas de repartir las etiquetas, y se calcularon todas. Aquí el valor p es exacto y unilateral: la proporción de esas 3003 asignaciones con un AUC igual o mayor que el observado, contando los empates. Esa distribución exacta indica que, por puro azar, un AUC de 0,771 o mayor aparece en el 5 % de los casos, de modo que ese es el valor que el modelo tendría que alcanzar para superar el azar con la significancia habitual. Usar la referencia de un protocolo en el otro llevaría a conclusiones falsas, en un sentido o en el otro.

Intervalos de confianza. Los intervalos del 95 % se obtuvieron por *bootstrap* percentil: los pacientes se remuestrean con reemplazo 2000 veces, con semilla fija, se recalcula el AUC en cada réplica y el intervalo lo forman los percentiles 2,5 y 97,5. Las réplicas que quedan con una sola clase se descartan, porque en ellas el AUC no existe. Con 17 y 14 pacientes, el método tiene dos límites que conviene declarar. El intervalo percentil tiende a quedarse corto en muestras pequeñas, de modo que los intervalos reportados son, si acaso, optimistas. Y en la validación cruzada solo recoge la variación debida a qué pacientes se observaron, no la debida a que cada predicción provino de un modelo distinto. Por último, un valor p mayor que 0,05 no demuestra que el modelo equivalga al azar: indica que con estos datos no se encontró evidencia de que lo supere.

El conjunto de prueba retenido. El modelo congelado se aplicó una sola vez a los pacientes reservados desde el principio, con exactamente el mismo preprocesamiento, las mismas características y las mismas 200 épocas por paciente, sin reajustar nada. El protocolo, incluida la referencia de azar, quedó fijado por escrito antes de la ejecución. Como se describió al presentar la cohorte, el conjunto

evaluado fue de **14 pacientes**, 8 con desenlace favorable y 6 con desenlace desfavorable, tras excluir al paciente 0356 por no tener registro dentro de la ventana.

Capítulo 7

Resultados

7.1 Resultados del Preprocesamiento de Señales

El preprocesamiento se aplicó a los 17 pacientes del conjunto de desarrollo, 9 con desenlace favorable y 8 con desenlace desfavorable. La Tabla 7.1 resume lo ocurrido con cada uno. En total se obtuvieron **83 243 épocas candidatas**, de las cuales se rechazaron **4988 (6,0 %)**: 2354 por estar planas y 2634 por presentar valores extremos. La proporción rechazada varía mucho entre pacientes, con una mediana de 4,0 % y un rango que va de prácticamente cero hasta el 36,6 % del paciente 0319. Los dos pacientes con más épocas planas, 0319 y 0424, concentran el 85 % de todas las épocas planas del conjunto.

Tres observaciones completan la tabla. La primera es que **todos los pacientes alcanzaron el tope de 2000 épocas**, incluido el que menos épocas limpias tenía (0418, con 2951), de modo que ningún paciente pesa menos que otro en el entrenamiento. La segunda es que dos pacientes, 0346 y 0418, tenían menos segmentos dentro de la ventana que los 16 que el procedimiento busca, y se procesaron todos los disponibles. La tercera es una comprobación de reproducibilidad: al volver a ejecutar el preprocesamiento completo de los 17 pacientes se obtuvieron las mismas épocas que las guardadas en disco, con diferencias menores que el redondeo propio de almacenar los datos en precisión simple. El conjunto final quedó formado por **34 000 épocas**, 2000 por paciente, cada una con 19 canales y 1000 muestras.

7.2 Resultados de la Extracción de Características

La extracción produjo una matriz de **34 000 filas** (17 pacientes por 2000 épocas) y **380 columnas** (20 características por 19 canales), sin ningún valor faltante ni infinito.

Tabla 7.1: Resultado del preprocesamiento por paciente: segmentos procesados frente a los disponibles dentro de la ventana, épocas candidatas, épocas rechazadas por estar planas o por valores extremos, y épocas conservadas tras aplicar el tope.

Paciente	Desenlace	Segmentos	Candidatas	Planas	Extremas	Rechazo	Conservadas
0284	Favorable	16 / 59	4238	0	97	2,3 %	2000
0286	Favorable	16 / 59	4510	4	234	5,3 %	2000
0299	Favorable	16 / 26	5565	0	221	4,0 %	2000
0311	Favorable	16 / 18	5256	0	40	0,8 %	2000
0319	Favorable	16 / 22	5020	912	926	36,6 %	2000
0335	Favorable	16 / 50	5616	0	5	0,1 %	2000
0337	Favorable	16 / 62	4676	0	5	0,1 %	2000
0422	Favorable	16 / 31	4980	69	155	4,5 %	2000
0424	Favorable	16 / 49	5760	1080	0	18,8 %	2000
0344	Desfavorable	16 / 61	4678	11	230	5,2 %	2000
0346	Desfavorable	15 / 15	5088	0	23	0,5 %	2000
0348	Desfavorable	16 / 51	5274	0	18	0,3 %	2000
0371	Desfavorable	16 / 23	4585	0	325	7,1 %	2000
0406	Desfavorable	16 / 61	4539	0	1	0,0 %	2000
0418	Desfavorable	9 / 9	3119	16	152	5,4 %	2000
0463	Desfavorable	16 / 27	5662	262	97	6,3 %	2000
0525	Desfavorable	16 / 61	4677	0	105	2,2 %	2000
Total			83 243	2354	2634	6,0 %	34 000

Para ver cómo se distribuyen las características entre las dos clases, la Figura 7.1 las resume tal como las recibe el modelo final, es decir, promediadas sobre los 19 canales. Cada paciente aporta un único punto por característica, la mediana de sus 2000 épocas. Se dibuja así porque la unidad real del estudio es el paciente: dibujar las 34 000 épocas daría la impresión de disponer de muchos más datos independientes de los que en realidad hay, ya que las épocas de un mismo paciente se parecen mucho entre sí.

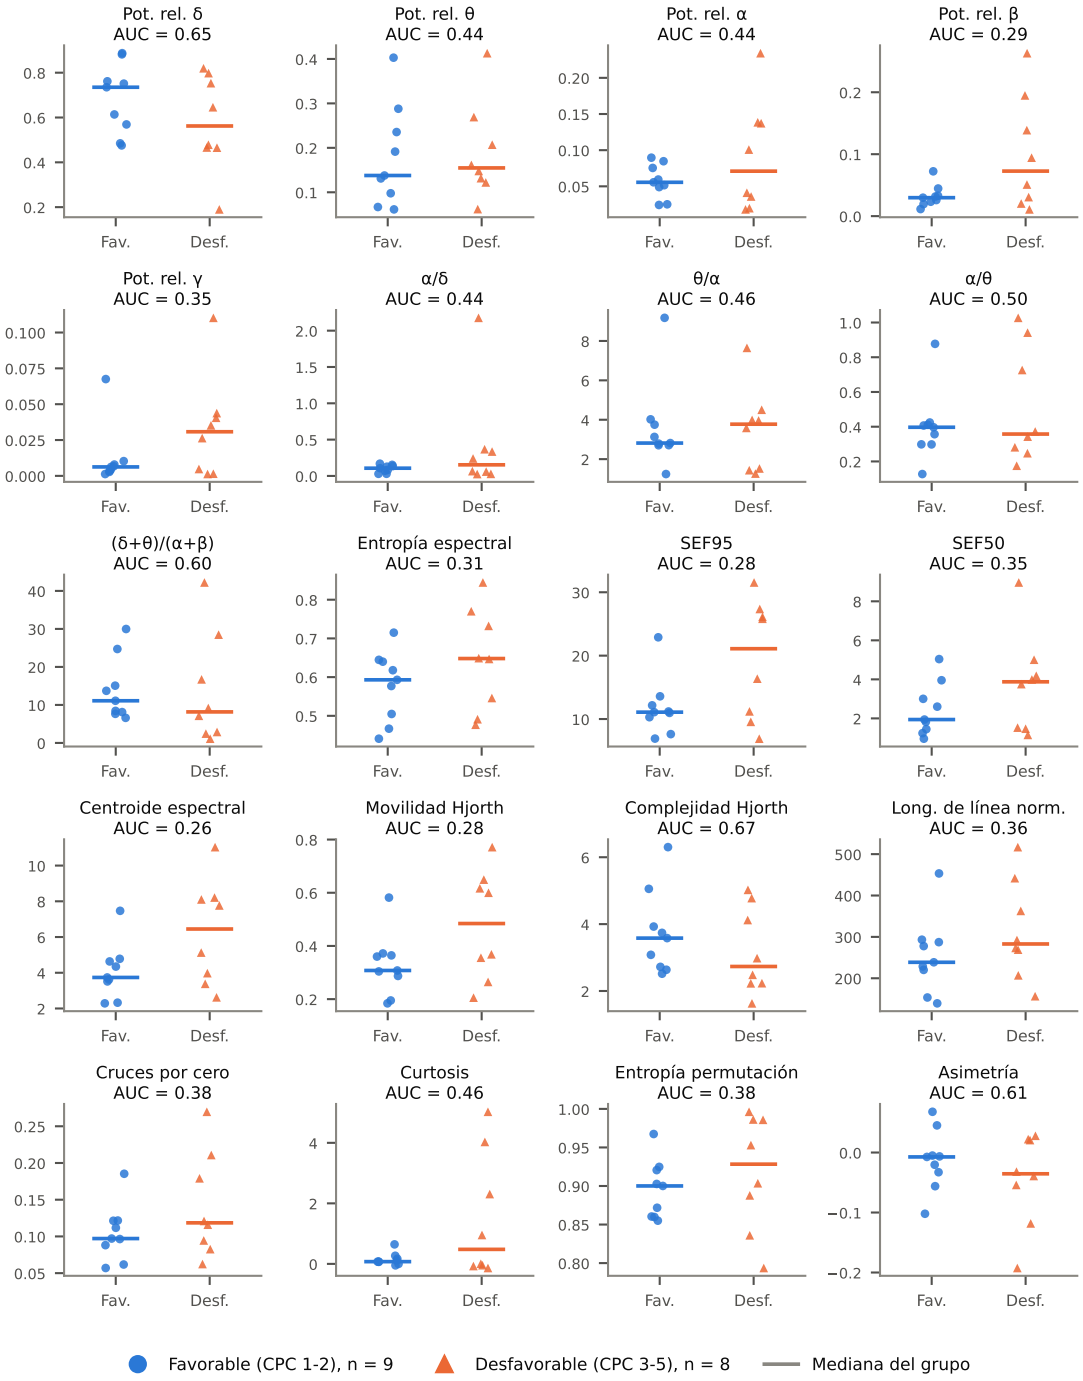


Figura 7.1: Las 20 características promediadas sobre los 19 canales, con un punto por paciente (la mediana de sus 2000 épocas): 9 pacientes con desenlace favorable y 8 con desenlace desfavorable. La línea horizontal marca la mediana de cada grupo. El AUC de cada panel se calcula con esa sola característica sobre los mismos 17 pacientes y sin validación; es una medida descriptiva de cuánto se solapan los grupos, no un resultado del modelo. Un valor de 0,5 indica solapamiento total, y cuanto más se aleja de 0,5, en cualquier dirección, más separados están.

La figura permite leer dos resultados. El primero es que **ninguna característica separa por sí sola las dos clases**. Los AUC descriptivos van de 0,26 a 0,67, y al comparar los dos grupos con la prueba de Mann-Whitney el valor p más bajo de las 20 características es 0,114, correspondiente al centroide espectral. Ninguna alcanza el umbral habitual de 0,05, y eso sin aplicar todavía ninguna corrección por haber realizado 20 comparaciones a la vez.

El segundo resultado es que **el grupo con desenlace desfavorable es mucho más disperso que el favorable**. Los pacientes que evolucionaron bien forman un grupo compacto, mientras que los que evolucionaron mal aparecen repartidos tanto por encima como por debajo de ellos. Medido con el rango intercuartílico, la dispersión del grupo desfavorable es mayor en 19 de las 20 características, entre 1,6 y 27 veces la del grupo favorable. Cuando uno de los grupos se reparte a ambos lados del otro, ninguna regla del tipo «valores altos indican mal pronóstico» puede separarlos, lo que es coherente con el resultado del modelado que se presenta en la Sección 7.3. La interpretación de esta heterogeneidad se aborda en el Capítulo 8.

7.3 Resultados del Modelado y la Validación Cruzada

Exploración. Las 84 configuraciones de la exploración inicial (combinaciones de algoritmo, forma de reducir las columnas y número de épocas por paciente) se evaluaron con la validación dejando un paciente fuera. Ninguna se reporta como resultado, porque elegir la mejor de 84 sobre los mismos 17 pacientes infla su valor. Lo que sí muestran es un panorama: en 55 de las 76 configuraciones que no correspondían al clasificador trivial, el AUC quedó por debajo de 0,5, y el máximo fue 0,625. Con el azar de este protocolo centrado en 0,388, ese panorama es el esperable cuando no hay una señal fuerte que encontrar.

Estimación con validación anidada. En las 17 particiones, la selección interna eligió siempre el mismo candidato, el clasificador de potenciación del gradiente. La Tabla 7.2 resume su desempeño sobre los 17 pacientes de desarrollo, cada uno evaluado por un modelo que no lo vio.

Tabla 7.2: Desempeño del modelo en la validación cruzada anidada, calculado a nivel de paciente (n = 17: 9 favorables y 8 desfavorables). El intervalo de confianza del 95 % se obtuvo remuestreando pacientes 2000 veces.

Métrica	Valor
AUC	0,556 [0,242, 0,848]
Exactitud balanceada	0,625
Sensibilidad (favorables reconocidos)	1,000 (9 de 9)
Especificidad (desfavorables reconocidos)	0,250 (2 de 8)
Puntuación de Brier	0,252
Azar de este protocolo (media de la nula)	0,388
Valor p frente a esa nula	0,178

El AUC de 0,556 queda por encima del centro del azar de este protocolo, pero dentro de su rango habitual: en 17 de las 100 permutaciones con etiquetas barajadas se obtuvo un valor igual o mayor, lo que da un valor p de 0,178 (Figura 7.2, panel a). **La validación anidada no muestra evidencia de que el modelo distinga las dos clases mejor que el azar.**

La combinación de sensibilidad y especificidad describe el comportamiento concreto del modelo: le asigna una probabilidad de desenlace favorable de 0,5 o más a casi todos los pacientes. Reconoce a los 9 favorables, pero también clasifica como favorables a 6 de los 8 desfavorables (Figura 7.3, panel a). En promedio, la probabilidad que asignó fue 0,642, cuando la proporción real de favorables es 0,529. Por último, la regla con que se combinan las épocas de un paciente se fijó de antemano en el promedio; con la mediana el AUC habría sido 0,583, y con las otras dos reglas evaluadas, 0,528 y 0,556, diferencias que no cambian la conclusión.

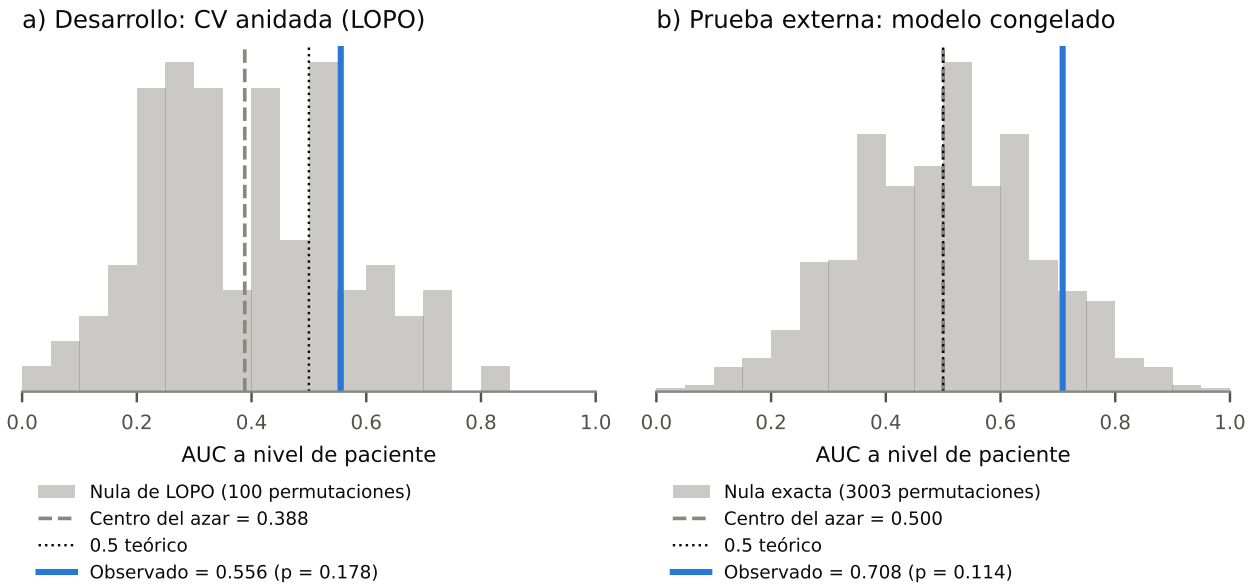


Figura 7.2: Cada resultado frente al azar de su propio protocolo. a) El AUC de la validación anidada (0,556) sobre la distribución obtenida repitiendo la validación con las etiquetas barajadas 100 veces, cuyo centro está en 0,388 y no en 0,5. b) El AUC sobre el conjunto de prueba retenido (0,708) sobre las 3003 formas posibles de repartir las etiquetas entre sus 14 pacientes, cuyo centro sí está en 0,5 porque el modelo congelado no se vuelve a entrenar. En ninguno de los dos casos el resultado se aleja lo suficiente del azar para considerarse significativo.

7.4 Resultados de la Evaluación Held-Out

El modelo congelado se aplicó una única vez a los 14 pacientes del conjunto de prueba retenido, 200 épocas por paciente, 2800 en total. La Tabla 7.3 recoge el resultado.

Tabla 7.3: Desempeño del modelo congelado sobre el conjunto de prueba retenido, a nivel de paciente ($n = 14$: 8 favorables y 6 desfavorables). El intervalo de confianza del 95 % se obtuvo remuestreando pacientes 2000 veces.

Métrica	Valor
AUC	0,708 [0,375, 0,959]
Exactitud balanceada	0,646
Sensibilidad (favorables reconocidos)	0,625 (5 de 8)
Especificidad (desfavorables reconocidos)	0,667 (4 de 6)
Puntuación de Brier	0,234
Azar de este protocolo (nula exacta)	0,500
AUC necesario para superar el azar ($p < 0,05$)	0,771
Valor p exacto	0,114

El AUC de 0,708 queda por encima de 0,5, pero no alcanza el 0,771 necesario para descartar el azar: el 11,4 % de las 3003 formas posibles de repartir las etiquetas produce un valor igual o mayor (Figura 7.2, panel b). El intervalo de confianza, que va de 0,375 a 0,959, incluye holgadamente el 0,5. **Sobre pacientes nuevos, el modelo tampoco muestra evidencia de discriminar mejor que el azar.**

A primera vista, 0,708 parece bastante mejor que el 0,556 de la validación anidada, pero los dos números no se pueden comparar de forma directa, porque cada uno se mide contra un azar distinto. Expresados como distancia a su propio azar, en unidades de su desviación típica, el resultado de la validación anidada está a 0,98 desviaciones $((0{,}556 - 0{,}388)/0{,}171)$ y el del conjunto de prueba retenido a 1,29 $((0{,}708 - 0{,}5)/0{,}161)$. Medidos con su propia vara, los dos resultados son muy parecidos.

A diferencia de lo ocurrido en desarrollo, en el conjunto de prueba retenido el modelo sí asignó probabilidades bajas a varios pacientes (Figura 7.3, panel b). Entre sus errores destaca el del paciente 0328, con desenlace favorable, al que el modelo le asignó una probabilidad de desenlace favorable de apenas **0,045**: un error cometido con mucha seguridad y en la dirección más delicada para una herramienta que pretende apoyar decisiones sobre el soporte vital.

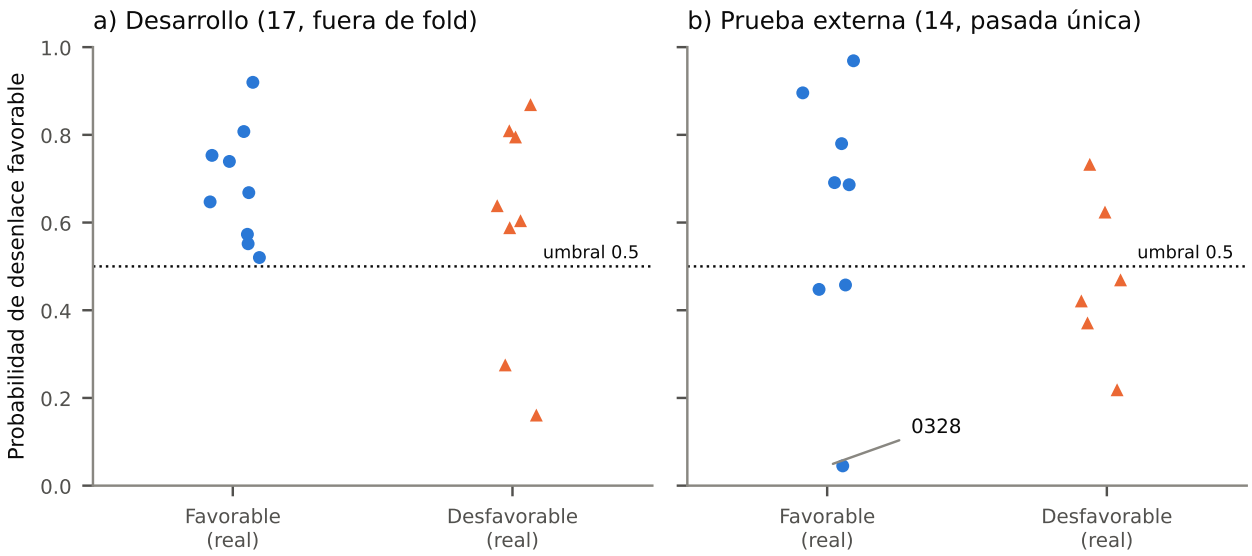


Figura 7.3: Probabilidad de desenlace favorable asignada a cada paciente, separada según su desenlace real. La línea punteada es el umbral de decisión: por encima, el pronóstico es favorable. a) Desarrollo: cada paciente evaluado por el modelo de la partición en la que quedó fuera. Los 9 favorables quedan por encima del umbral, pero también 6 de los 8 desfavorables. b) Conjunto de prueba retenido, en su única evaluación. Se señala el paciente 0328, con desenlace favorable y una probabilidad asignada de 0,045.

Estos resultados se obtuvieron sobre un conjunto de prueba retenido que no contiene ningún paciente con CPC 2 o CPC 3, los casos vecinos a la línea de corte, por las razones expuestas en la Sección 6.2.1. Su efecto sobre la lectura del 0,708 se discute en el Capítulo 8.

7.5 Costo Computacional

El objetivo específico 4 y la segunda parte de la hipótesis se refieren al costo computacional del sistema: cuánto tarda en entrenarse, cuánto tarda en producir un pronóstico y qué equipo necesita. Ese costo se midió directamente sobre el sistema construido, en el mismo computador en que se desarrolló todo el trabajo: un portátil con un procesador AMD Ryzen 5 PRO 5650U de 6 núcleos (12 hilos), 27 GB de memoria RAM y sistema operativo Linux, con Python 3.12 y scikit-learn 1.8. El equipo no tiene tarjeta gráfica dedicada, solo la gráfica integrada en el propio procesador, y ninguna parte del sistema la utiliza: todas las bibliotecas empleadas en el preprocesamiento, la extracción de características y el modelado trabajan exclusivamente sobre el procesador. La biblioteca de

aprendizaje profundo PyTorch figura entre las dependencias instaladas del proyecto, pero ningún archivo del sistema la utiliza.

Se midieron tres etapas, cada una en un proceso independiente para que la memoria de una no se sumara a la de otra. La primera es el camino completo de un paciente nuevo, desde sus archivos de EEG crudo hasta sus 380 características por época, sin escribir nada en disco; se repitió tres veces con el paciente 0284. La segunda es el entrenamiento del modelo final con los 17 pacientes, repetido diez veces tras una ejecución previa de calentamiento que no se contabiliza, porque la primera ejecución incluye cargas iniciales que no representan el costo real. La tercera es el pronóstico de un paciente con el modelo congelado, repetido cien veces. Los tiempos corresponden a la configuración por defecto de las bibliotecas, sin ajustes de rendimiento.

Tabla 7.4: Costo computacional medido en un portátil sin tarjeta gráfica dedicada (AMD Ryzen 5 PRO 5650U, 6 núcleos, 27 GB de RAM). Los tiempos del paciente son el rango de tres repeticiones; el del entrenamiento es la mediana de diez; el de la predicción, la mediana de cien.

Etapa	Tiempo	Memoria máxima
Preprocesamiento de un paciente (EEG crudo a 2000 épocas limpias)	59–60 s	3,5 GB
Extracción de características de ese paciente (380 por época)	4,2 s	
Entrenamiento del modelo final (17 pacientes, 3400 filas)	0,15 s	0,6 GB
Validación cruzada anidada completa (17 particiones, 6 candidatos)	71 s	
Pronóstico de un paciente con el modelo congelado (200 épocas)	3 ms	0,6 GB

La Tabla 7.4 resume los resultados. Producir el pronóstico de un paciente nuevo a partir de su EEG crudo toma alrededor de **un minuto**, y más del 90 % de ese tiempo corresponde al preprocesamiento de la señal; el modelo en sí responde en unos 3 milisegundos. El entrenamiento del modelo final tarda menos de dos décimas de segundo, y toda la validación cruzada anidada, que entrena más de 400 modelos, algo más de un minuto. El modelo congelado ocupa 265 KB en disco. La mayor exigencia de memoria, unos 3,5 GB, aparece durante el preprocesamiento, cuando se cargan los segmentos de EEG de un paciente; el entrenamiento no supera los 0,6 GB, de los cuales la mayor parte corresponde a cargar la tabla completa de características. Como verificación adicional, al volver a ejecutar la validación cruzada anidada para medir su tiempo se obtuvo exactamente el mismo AUC reportado en la Sección 7.3, 0,556.

Tres partes del trabajo no se volvieron a cronometrar y se declaran como tales: la descarga de los datos, que depende de la conexión a internet; el preprocesamiento de los 17 pacientes de desarrollo en conjunto, que a partir de la medición individual puede estimarse en unos 18 minutos, sin que esa cifra se haya medido; y la exploración de 84 configuraciones junto con las 100 repeticiones con que se midió el azar, que se ejecutaron una sola vez durante el desarrollo.

Con estas cifras, la segunda parte de la hipótesis se cumple: el sistema completo se entrena, se valida y produce pronósticos en un computador portátil de uso común, sin tarjeta gráfica especializada, en tiempos que van de milisegundos a pocos minutos.

Capítulo 8

Discusión

8.1 Interpretación de los Resultados Principales

La respuesta a la hipótesis. La hipótesis de este trabajo tenía dos partes (Sección 3.3). La primera afirmaba que un modelo clásico, a partir de características extraídas del EEG, distinguiría entre desenlace favorable y desfavorable con un AUC que cumpliera dos condiciones a la vez: diferenciarse del azar de su protocolo de validación con $p < 0{,}05$ y alcanzar al menos 0,70, el umbral operativo fijado en la hipótesis. **Esa parte no se confirma.** La validación anidada sobre los 17 pacientes de desarrollo no cumple ninguna de las dos (AUC 0,556, $p = 0{,}178$). El conjunto de prueba retenido de 14 pacientes nuevos alcanza el valor de 0,70 (AUC 0,708), pero no la primera condición ($p = 0{,}114$): con 14 pacientes un valor así está dentro de lo que el azar produce, y su intervalo de confianza, de 0,375 a 0,959, abarca desde un modelo inútil hasta uno excelente. Superar el umbral sin superar el azar no confirma nada, y por eso la hipótesis exigía las dos condiciones juntas. La segunda parte, referida al costo computacional, **sí se cumple**: el sistema completo se entrena en menos de dos décimas de segundo, produce el pronóstico de un paciente nuevo a partir de su EEG crudo en alrededor de un minuto y funciona en un portátil sin tarjeta gráfica dedicada (Sección 7.5).

Un resultado negativo no equivale a un modelo que no funciona. Lo que el resultado dice con precisión es que *con este diseño* no se puede afirmar que el modelo distinga las clases; no dice que el EEG no contenga información pronóstica, algo que la literatura clínica ya establece (Benghanem et al., 2022; Rossetti et al., 2016). Las secciones que siguen examinan por qué el diseño no alcanzó a detectarla.

Por qué el 0,708 no contradice al 0,556. La diferencia entre los dos números es, sobre todo, una diferencia de referencia: medidos como distancia a su propio azar, los dos resultados quedan a 0,98 y 1,29 desviaciones típicas, respectivamente (Sección 7.4). Hay además una razón para leer el 0,708 con cautela adicional. El conjunto de prueba retenido no contiene ningún paciente con CPC 2 o CPC 3, los casos situados junto a la línea que separa las dos clases, mientras que en el conjunto de desarrollo esos casos son 9 de 17 (Sección 6.2.1). Distinguir a un paciente con CPC 1 de uno con CPC 5 es una tarea más fácil que distinguir a uno con CPC 2 de uno con CPC 3, de modo que el conjunto de prueba retenido le planteó al modelo una tarea más sencilla que la de desarrollo. Si el 0,708 está inflado por algo, es por eso, y no a la inversa.

Primera explicación: el tamaño de la muestra. La explicación más directa es que 17 pacientes no bastan para detectar una señal de intensidad moderada. Una forma de comprobarlo es aplicar el mismo protocolo a predictores cuyo valor pronóstico está establecido. Con una regresión logística que usa únicamente la edad del paciente y si el ritmo cardíaco inicial fue desfibrilable, dos variables clínicas que se registran en I-CARE, el AUC sobre los mismos 17 pacientes es de 0,806 cuando se mide sobre los datos con que se ajustó el modelo, pero cae a **0,486** cuando se evalúa dejando un paciente fuera, por debajo del 0,556 del modelo basado en EEG. Con variantes menores del mismo modelo, el segundo valor se mueve entre 0,44 y 0,54, pero nunca se aleja del azar. Es decir, con 17 pacientes tampoco funcionan los predictores clínicos conocidos. Esto no demuestra que el EEG sea informativo, pero sí indica que el resultado negativo es, al menos en parte, consecuencia de la potencia del diseño y no solo del modelo. La misma comparación ilustra por qué la validación honesta es imprescindible: la diferencia entre 0,806 y 0,486 no la produce el modelo, la produce la forma de medirlo.

Segunda explicación: lo que no se pudo medir. El patrón con más peso pronóstico en la literatura, la supresión de la actividad de fondo, se define por la amplitud de la señal, y las amplitudes de este conjunto de datos no están calibradas (Sección 5.2.3). Para no introducir diferencias entre equipos se usaron solo características que no dependen de la amplitud, y eso dejó fuera, precisamente,

la información que la práctica clínica considera más útil. El modelo trabajó sin el marcador más fuerte disponible.

Tercera explicación: el grupo desfavorable no es un solo grupo. La Figura 7.1 mostró que los pacientes con desenlace favorable forman un grupo compacto, mientras que los desfavorables se reparten a ambos lados de ellos, con una dispersión mayor en 19 de las 20 características. Una interpretación posible, que este trabajo *no* ha podido verificar, es que el desenlace desfavorable agrupa mecanismos distintos: algunos pacientes presentarían un EEG enlentecido y otros un EEG muy suprimido, casi plano, en el que el ruido y la actividad muscular, que ocupan todas las frecuencias, pesan tanto en el espectro que lo hacen parecer rápido. Si fuera así, ninguna regla del tipo «más lento indica peor pronóstico» podría separarlos, y un modelo necesitaría más ejemplos de cada mecanismo para aprender a reconocerlos por separado. Comprobarlo exigiría medir la supresión, lo que remite de nuevo a la limitación anterior.

Una explicación que sí se descartó: el hospital. En el conjunto de desarrollo, dos hospitales con dos pacientes cada uno tienen todos sus pacientes en la misma clase, lo que plantea la sospecha de que el modelo pudiera aprender a reconocer el hospital en lugar del desenlace. Se midió con una prueba de permutación: se barajó el desenlace entre los 17 pacientes 5000 veces y se comparó la asociación entre hospital y desenlace con la observada. El resultado ($p = 0{,}457$) indica que la asociación observada es la esperable por azar. El hospital dominante, que reúne 11 de los 17 pacientes, está además equilibrado, con 6 favorables y 5 desfavorables. Con tan pocos pacientes en los hospitales pequeños, sin embargo, el diseño no puede descartar esta sospecha por completo, y por eso figura también entre las limitaciones.

Lo que el trabajo sí aporta. El resultado de esta primera versión no es un modelo listo para usarse, sino una línea base honesta: un flujo completo y reproducible desde la señal cruda hasta el pronóstico, en el que cada paso está verificado y cada decisión declarada, y una medida de cuánto se puede esperar con este diseño. Aporta también una lección metodológica con consecuencias prácticas: el azar depende del protocolo, y usar la referencia equivocada lleva a errores en los dos

sentidos. Comparar la validación dejando un paciente fuera contra 0,5 habría hecho leer como «peor que el azar» a la mayoría de las configuraciones exploradas, cuando su azar real está en 0,388. Comparar el conjunto de prueba retenido contra ese 0,388, en lugar de contra 0,5, habría situado el 0,708 a 1,87 desviaciones del azar y lo habría hecho parecer casi significativo. Por último, el caso del paciente 0328, con desenlace favorable y una probabilidad asignada de 0,045, recuerda el encuadre de todo el trabajo: una herramienta como esta solo puede apoyar el juicio clínico, nunca reemplazarlo, y esta versión en particular no debe usarse para tomar decisiones sobre pacientes reales.

8.2 Comparación con la Literatura

Este trabajo se compara con dos referentes: un estudio clínico que usa aprendizaje de máquina clásico y la competencia internacional que utilizó la misma base de datos. El primero es el de Carrasco-Gómez et al. (2021), que también predice el desenlace de pacientes en coma tras un paro cardíaco a partir del EEG y con aprendizaje de máquina clásico. Las dos investigaciones comparten tres rasgos: la misma división de las clases (CPC 1-2 frente a CPC 3-5), un montaje de 19 canales y el uso de árboles de decisión combinados entre los modelos evaluados. La diferencia principal está en el tamaño: ese estudio incluyó 594 pacientes, alrededor de 35 veces los 17 del conjunto de desarrollo de este trabajo, y reservó el 20 % de ellos como conjunto de prueba. Con 44 características que describen la señal sin relacionar canales entre sí, del mismo tipo que las de este trabajo (frecuencia, amplitud y entropía), su modelo alcanzó un AUC de 0,89, con un intervalo de confianza de 0,83 a 0,91; al añadir medidas de conectividad entre canales llegó a 0,92.

La comparación no dice que ese modelo sea mejor que el de este trabajo en ningún sentido práctico, porque los dos resultados provienen de diseños muy distintos. Lo que sí muestra, y es lo que importa aquí, es la anchura de los intervalos: con 594 pacientes el intervalo mide 0,08, mientras que con 17 el de este trabajo mide 0,61 (de 0,242 a 0,848). La misma familia de características, medida en una cohorte grande, produce una estimación precisa y claramente superior al azar. Esto es coherente con la lectura de la Sección 8.1: el obstáculo de este trabajo es la potencia del diseño,

no necesariamente el tipo de características elegidas. El mismo estudio recoge un trabajo anterior que, con conectividad funcional y 94 pacientes, reportó un AUC de 0,81. Incluso esa cohorte es más de cinco veces la de este trabajo.

El segundo referente es el George B. Moody PhysioNet Challenge 2023 (Reyna et al., 2023), una competencia internacional construida precisamente sobre la base de datos I-CARE: 1020 pacientes de siete hospitales, registrados con los mismos 19 canales que usa este trabajo y con la misma división de las clases. Participaron 111 equipos de todo el mundo. Sus resultados no se pueden poner al lado de los de este trabajo, porque el Challenge no evaluó con el AUC: su puntuación es la proporción de pacientes con desenlace desfavorable que el algoritmo identifica cuando se le permite equivocarse, como máximo, con el 5 % de los pacientes con desenlace favorable de cada hospital, y se midió con los registros de las primeras 72 horas tras la reanimación. Sí ofrece tres observaciones que coinciden con las de este trabajo. La primera es la caída del rendimiento fuera de los datos de entrenamiento: los tres mejores equipos obtuvieron entre 0,958 y 1,000 sobre sus datos de entrenamiento y entre 0,718 y 0,792 sobre el conjunto de prueba oculto, el mismo fenómeno que llevó a la línea base clínica de este trabajo de 0,806 a 0,486 al evaluarla con pacientes no vistos. La segunda es de diseño: el Challenge reservó a propósito todos los pacientes de un hospital para el conjunto de prueba, con el fin de medir si los algoritmos generalizaban a un hospital nuevo. En este trabajo ocurrió lo mismo con el hospital D, aunque no por diseño sino como efecto de la selección (Sección 6.2.1). La tercera es que, según sus organizadores, extraer características guiadas por el conocimiento clínico fue importante para que los algoritmos pudieran entrenarse con los recursos de cómputo disponibles, lo que respalda el enfoque de este trabajo y su atención al costo computacional.

Los dos referentes comparten además un enfoque clínico que conviene declarar. Ninguno optimiza el AUC: los dos miden cuántos pacientes con mal pronóstico se detectan cuando el error con los que se recuperarían se limita a casi nada, a ninguno en el estudio de Carrasco-Gómez y a un máximo del 5 % en el Challenge (Carrasco-Gómez et al., 2021; Reyna et al., 2023). La razón es la consecuencia del error: un pronóstico pesimista equivocado puede llevar a retirar el soporte vital a alguien que habría recuperado su independencia (Reyna et al., 2023). Este trabajo no puede reportar

esa métrica de forma útil, porque con solo 8 pacientes favorables en el conjunto de prueba retenido cada uno equivale a un 12,5 % de ellos, y una estimación tan gruesa no permite afirmar nada sobre esos márgenes de error. El caso del paciente 0328, con desenlace favorable y una probabilidad asignada de 0,045, es precisamente el tipo de error que ese criterio está diseñado para impedir.

Por último, el tamaño reducido de la muestra no solo ensancha los intervalos: también es la condición en la que el error de la propia evaluación puede ser mayor que las diferencias que se reportan (Varoquaux & Cheplygina, 2022). En ese sentido, el resultado negativo de este trabajo, medido con separación estricta por paciente y contrastado en un conjunto retenido, es más informativo que un resultado positivo obtenido con el mismo número de pacientes y sin esas salvaguardas.

8.3 Limitaciones del Estudio

Las limitaciones de este trabajo se agrupan en cinco frentes. Todas se conocían o se descubrieron durante el desarrollo, y se declaran junto con su consecuencia sobre lo que se puede afirmar.

1. El tamaño de la muestra. Es la limitación dominante. Con 17 pacientes de desarrollo y 14 de prueba retenida, los intervalos de confianza son muy amplios: el del AUC en validación anidada va de 0,242 a 0,848, y el del conjunto de prueba retenido, de 0,375 a 0,959. Intervalos así son compatibles tanto con un modelo inútil como con uno bueno, y por eso no permiten concluir en ningún sentido. Como se discutió en la sección anterior, con este tamaño tampoco funcionan los predictores clínicos establecidos. El alcance de prueba de concepto fue una decisión consciente, tomada por el volumen de la base de datos completa, y no una limitación descubierta al final.

2. La composición de los dos conjuntos. Los conjuntos de desarrollo y de prueba retenido no son comparables en tres aspectos (Sección 6.2.1). El conjunto de prueba retenido no contiene ningún caso vecino a la línea de corte (CPC 2 o 3), lo que lo convierte en una tarea más fácil; esto no se debió al azar, sino a que los dos conjuntos se seleccionaron mirando la etiqueta con distinto grado

de detalle. En consecuencia, el 0,708 mide únicamente la capacidad de separar los extremos de la escala, pues los 14 pacientes del conjunto retenido tienen CPC 1 o CPC 5, y no puede extrapolarse a la población completa de pacientes en coma tras un paro, donde los casos intermedios existen y son los más difíciles de pronosticar. Los tres pacientes del hospital D aparecen únicamente en el conjunto de prueba retenido, de modo que el modelo se evaluó en parte sobre un hospital que nunca vio al entrenar. Y el conjunto de desarrollo está dominado por un solo hospital (11 de 17 pacientes). A esto se suma que la muestra se equilibró a propósito en torno a la mitad de cada clase, mientras que en la base de datos completa solo el 36 % de los pacientes tiene desenlace favorable: los resultados corresponden a una muestra balanceada por diseño, y en la población real el valor de las métricas que dependen de esa proporción sería distinto. La asociación entre hospital y desenlace se midió y no resultó significativa ($p = 0{,}457$), pero con dos pacientes en algunos hospitales el diseño no puede descartarla del todo.

3. Lo que la señal permitió medir. Las amplitudes sin calibrar obligaron a usar solo características que no dependen del tamaño de la señal, lo que dejó fuera la supresión de fondo y la potencia absoluta, dos de los marcadores más informativos. La reactividad tampoco pudo evaluarse, porque los registros no indican cuándo se estimuló al paciente. Al promediar los 19 canales se perdió la información sobre dónde ocurre cada fenómeno, y en el caso de la asimetría, cuyos valores apenas se relacionan entre canales, el promedio borra información. La limpieza de la señal tiene además un alcance acotado: detecta los electrodos desconectados, pero no los que registran ruido excesivo, que entran en la referencia promedio común y reparten ese ruido entre los demás canales, ni los artefactos que afectan solo a unos pocos canales (Sección 6.2.2). Por último, de cada paciente se usó una fracción de la señal disponible: alrededor del 12 % de la ventana en el preprocesamiento (Sección 6.2.2) y, de ese material, 200 de sus 2000 épocas para el modelo. Se comprobó que el número de épocas no cambia el resultado, pero no se puede descartar que otra selección de la señal lo cambie.

4. Decisiones tomadas fuera de la validación anidada. La validación anidada protegió la elección del algoritmo, pero no la del número de épocas ni la del promedio de canales, que se fijaron después de explorar configuraciones con los mismos 17 pacientes (Sección 6.2.5). Tampoco incluyó las máquinas de vectores de soporte, que solo participaron en la exploración. El conjunto de prueba retenido, que no intervino en ninguna de estas decisiones, es la protección frente a ellas, y su resultado es coherente con el de desarrollo.

5. El comportamiento del modelo. En desarrollo, el modelo asignó a casi todos los pacientes una probabilidad de desenlace favorable de 0,5 o más, con una probabilidad media de 0,642 frente a una proporción real de 0,529. En el conjunto de prueba retenido cometió un error muy seguro en la dirección más delicada: al paciente 0328, que tuvo desenlace favorable, le asignó una probabilidad de 0,045. Además, el modelo trabaja solo con el EEG y no combina esa información con las variables clínicas del paciente, como se hace en la práctica, y, por diseño, no se comparó con un modelo de aprendizaje profundo, que nunca se entrenó en este trabajo.

Una comparación registrada de antemano que no se ejecutó. Antes de conocer el resultado del conjunto de prueba retenido quedó registrada por escrito una segunda configuración, idéntica a la empleada salvo en la ventana de tiempo, que se reduce a las horas 24 a 48 después del paro. Su propósito es comprobar si una ventana más estrecha y más temprana produce señales más homogéneas entre pacientes; se verificó de antemano que no añade ningún paciente, porque los 31 que tienen registros entre las horas 24 y 72 también los tienen entre las 24 y las 48. Esa segunda configuración **no se ejecutó en esta versión**, por decisión deliberada, y su definición permanece fija para una versión posterior. Se declara aquí para que el registro previo sea verificable y no quede en silencio.

Todas estas limitaciones se retoman como líneas de trabajo futuro en el Capítulo 9.

Capítulo 9

Conclusiones

9.1 Conclusiones Generales

Este trabajo se propuso responder en qué medida un modelo de aprendizaje de máquina clásico, basado en características extraídas explícitamente del EEG, permite predecir el pronóstico neurológico de pacientes en coma tras un paro cardíaco. **Con el diseño empleado, no se encontró evidencia estadísticamente significativa de que lo permita, y la incertidumbre de las estimaciones tampoco permite descartarlo.** El AUC fue de 0,556 en la validación cruzada anidada ($p = 0{,}178$ frente a un azar de 0,388) y de 0,708 en el conjunto de prueba retenido ($p = 0{,}114$ frente a un azar de 0,5); en ninguno de los dos casos la prueba de permutación muestra evidencia estadísticamente significativa de una discriminación superior al azar, y sus intervalos de confianza son lo bastante amplios para ser compatibles con un modelo inútil y con uno bueno. La pregunta, por tanto, queda abierta, y lo que este trabajo establece es que 17 pacientes no alcanzan para cerrarla.

La hipótesis tenía dos partes, y el resultado es distinto para cada una. La primera, que el modelo alcanzara un AUC significativamente superior al azar ($p < 0{,}05$) y de al menos 0,70, **no se confirma**: el conjunto de prueba retenido llega a 0,708, pero ese valor no es estadísticamente significativo ($p = 0{,}114$), y la validación anidada no cumple ninguna de las dos condiciones. La segunda, que su costo computacional permitiera entrenarlo en un computador de uso común sin tarjeta gráfica especializada, **sí se cumple**: el modelo final se entrena en 0,15 segundos y el pronóstico de un paciente nuevo, desde su EEG crudo, toma alrededor de un minuto en un portátil sin tarjeta gráfica dedicada.

Respecto a los objetivos específicos:

1. **Preprocesamiento.** Se implementó un flujo de seis pasos que selecciona los 19 canales estándar, filtra, re-muestrea, re-referencia, segmenta en épocas de 10 segundos y rechaza las

épocas defectuosas con un criterio relativo a cada paciente. Rechazó el 6,0 % de las épocas procesadas y entregó 2000 épocas limpias por cada uno de los 17 pacientes. Al volver a ejecutarlo, los 17 resultados coincidieron con los guardados.

2. **Características.** Se extrajeron 20 características en cinco familias, que cubren el tiempo, la frecuencia y la complejidad de la señal, para cada uno de los 19 canales: 380 columnas por época, sin valores faltantes. Todas son independientes de la escala de la señal, condición necesaria porque las amplitudes de la base de datos no están calibradas, y esa propiedad se comprobó en las 20.
3. **Entrenamiento, validación y evaluación.** Se evaluaron cuatro familias de algoritmos clásicos con una validación cruzada anidada que mantiene siempre juntas las épocas de un mismo paciente, y el clasificador de potenciación del gradiente fue elegido en las 17 particiones. El rendimiento de la línea base se midió a nivel de paciente con el AUC, la exactitud balanceada, la sensibilidad y la especificidad; el AUC se comparó con el azar propio de cada protocolo de evaluación, y el modelo congelado se evaluó una sola vez sobre 14 pacientes que no vio hasta el final.
4. **Costo computacional.** Se midió el costo de todo el proceso en un portátil sin tarjeta gráfica dedicada: el preprocesamiento de un paciente toma alrededor de un minuto y la extracción de sus características, 4,2 segundos; el entrenamiento del modelo final, 0,15 segundos; la validación cruzada anidada completa, 71 segundos, y el pronóstico con el modelo congelado, 3 milisegundos. La mayor exigencia de memoria, 3,5 GB, aparece durante el preprocesamiento.

Los cuatro objetivos específicos y el objetivo general se cumplen: el resultado es una línea base de rendimiento y de costo, obtenida con un procedimiento documentado de principio a fin, que es lo que el objetivo general pedía. Lo que no se alcanzó es un modelo que discrimine mejor que el azar, y eso no era un objetivo sino la hipótesis que se puso a prueba. Una línea base cumple su función aunque su resultado sea negativo, siempre que el número sea honesto y el camino que lo produce sea reproducible, y esas dos condiciones sí se cumplen. En síntesis, el aporte de este trabajo es un flujo completo desde la señal cruda hasta el pronóstico, verificado paso por paso y con

cada decisión declarada, junto con dos lecciones que cualquier trabajo posterior sobre esta base de datos puede aprovechar: que el azar depende del protocolo de validación, y que con este número de pacientes ningún predictor, ni el EEG ni las variables clínicas establecidas, muestra evidencia estadísticamente significativa de discriminar mejor que el azar.

9.2 Trabajo Futuro

Las líneas de trabajo futuro se ordenan según las limitaciones del Capítulo 8, de modo que cada una tenga una respuesta concreta.

Aumentar la muestra. Es la línea prioritaria, porque la limitación dominante es la potencia del diseño. La base de datos I-CARE ofrece 607 pacientes, y el flujo de este trabajo puede aplicarse a una fracción mucho mayor sin cambios de fondo: el costo medido, de alrededor de un minuto de preprocesamiento por paciente en un portátil, lo hace viable, y llevaría el trabajo al mismo terreno en que compitieron los equipos del PhysioNet Challenge 2023 (Reyna et al., 2023). Con una cohorte grande conviene además conservar la proporción real de las clases, en lugar de la muestra equilibrada a mano, para que las métricas correspondan a la población en la que se usaría el modelo.

Seleccionar los conjuntos con el mismo criterio. Los dos conjuntos deberían elegirse mirando la etiqueta con el mismo grado de detalle, el nivel de CPC y no solo el desenlace agrupado, de modo que el conjunto de prueba retenido contenga casos vecinos a la línea de corte y represente a los mismos hospitales que el de desarrollo.

Validar en una cohorte externa. El conjunto de prueba de este trabajo es una partición retenida de la misma base, de modo que protege frente a la fuga de información, pero no mide si el modelo se generaliza a otros centros. Esa pregunta exige evaluar el modelo congelado sobre pacientes de hospitales que no aporten ningún dato al desarrollo, o de una cohorte distinta de I-CARE.

Ejecutar la comparación registrada de antemano. La configuración con ventana de 24 a 48 horas, cuya definición quedó fijada antes de conocer el resultado del conjunto de prueba retenido, está lista para ejecutarse en una versión posterior sin modificar su registro previo.

Ampliar lo que el modelo puede medir. Tres extensiones responden a lo que la señal no permitió en esta versión: incorporar medidas de conectividad entre canales, como las que mejoraron los resultados en la literatura sobre coma postanóxico (Carrasco-Gómez et al., 2021); conservar la información de cada canal o región en lugar de promediar los 19; y usar una fracción mayor de la ventana de cada paciente, comprobando si otra selección de la señal cambia el resultado. En la limpieza de la señal, conviene detectar también los canales ruidosos antes de calcular la referencia promedio común, que hoy solo excluye los canales planos. Se suma medir cuánto pesa cada característica en la predicción, que esta versión deja identificadas pero no evaluadas.

Proteger todas las decisiones dentro de la validación. El número de épocas por paciente y la forma de combinar los canales deberían elegirse dentro de la validación cruzada anidada, igual que el algoritmo, e incluir en ella todas las familias exploradas.

Acercar el modelo al uso clínico. Tres pasos lo acercarían a la forma en que se toman estas decisiones: combinar el EEG con las variables clínicas del paciente; reportar cuántos pacientes con mal pronóstico se detectan cuando el error con los que se recuperarían se limita a casi nada, la forma de evaluar que usan los dos referentes de la Sección 8.2, cuando el tamaño del conjunto de prueba lo permita; y ajustar las probabilidades del modelo para que correspondan a las frecuencias reales, de modo que errores como el del paciente 0328 se detecten antes de cualquier uso.

Comparar con el aprendizaje profundo. Con una cohorte suficiente, esta línea base queda disponible como punto de comparación para un modelo de aprendizaje profundo entrenado sobre los mismos pacientes y con la misma separación por paciente, que es el propósito para el que fue construida.

Referencias

Amorim, E., Zheng, W.-L., & Ghassemi, M. M. (2023). The International Cardiac Arrest Research (I-CARE) Consortium Electroencephalography Database. *Critical Care Medicine*. https://doi.org/10.1097/ccm.0000000000006074

Bandt, C., & Pompe, B. (2002). Permutation Entropy: A Natural Complexity Measure for Time Series. *Physical Review Letters*, *88*(17), 174102. https://doi.org/10.1103/PhysRevLett.88.174102

Benghanem, S., Pruvost-Robieux, E., Bouchereau, E., Gavaret, M., & Cariou, A. (2022). Prognostication after Cardiac Arrest: How EEG and Evoked Potentials May Improve the Challenge. *Annals of Intensive Care*. https://doi.org/10.1186/s13613-022-01083-9

Bigdely-Shamlo, N., Mullen, T., Kothe, C., Su, K.-M., & Robbins, K. A. (2015). The PREP Pipeline: Standardized Preprocessing for Large-Scale EEG Analysis. *Frontiers in Neuroinformatics*. https://doi.org/10.3389/fninf.2015.00016

Breiman, L. (2001). Random Forests. *Machine Learning*. https://doi.org/10.1023/a:1010933404324

Carrasco-Gómez, M., Keijzer, H. M., Ruijter, B. J., & Bruña, R. (2021). EEG Functional Connectivity Contributes to Outcome Prediction of Postanoxic Coma. *Clinical Neurophysiology*. https://doi.org/10.1016/j.clinph.2021.02.011

Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*. https://doi.org/10.1007/bf00994018

Ezugwu, A. E., Ho, Y.-S., Egwuche, O. S., & Ekundayo, O. S. (2025). Classical Machine Learning: Seventy Years of Algorithmic Learning Evolution. *Data Intelligence*. https://doi.org/10.3724/2096-7004.di.2024.0051

Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C.-K., & Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*. https://doi.org/10.1161/01.cir.101.23.e215

Hanley, J. A., & McNeil, B. J. (1982). The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve. *Radiology*. https://doi.org/10.1148/radiology.143.1.7063747

Herman, S. T., Abend, N. S., Bleck, T. P., & Chapman, K. E. (2015). Consensus Statement on Continuous EEG in Critically Ill Adults and Children, Part I. *Journal of Clinical Neurophysiology*. https://doi.org/10.1097/wnp.0000000000000166

Hjorth, B. (1970). EEG Analysis Based on Time Domain Properties. *Electroencephalography and Clinical Neurophysiology*, *29*(3), 306-310. https://doi.org/10.1016/0013-4694(70)90143-4

Maleki, F., Muthukrishnan, N., Ovens, K., & Reinhold, C. (2020). Machine Learning Algorithm Validation. *Neuroimaging Clinics of North America*. https://doi.org/10.1016/j.nic.2020.08.004

Mandrekar, J. N. (2010). Receiver Operating Characteristic Curve in Diagnostic Test Assessment. *Journal of Thoracic Oncology*, *5*(9), 1315-1316. https://doi.org/10.1097/JTO.0b013e3181ec173d

Rajajee, V., Muehlschlegel, S., Wartenberg, K. E., Alexander, S. A., Busl, K. M., Chou, S. H. Y., Creutzfeldt, C. J., Fontaine, G. V., Fried, H., Hocker, S. E., Hwang, D. Y., Kim, K. S., Madzar, D., Mahanes, D., Mainali, S., Meixensberger, J., Montellano, F., Sakowitz, O. W., Weimar, C., . . . Varelas, P. N. (2023). Guidelines for Neuroprognostication in Comatose Adult Survivors of Cardiac Arrest. *Neurocritical Care*. https://doi.org/10.1007/s12028-023-01688-3

Rayi, A., & Murr, N. I. (2022). Electroencephalogram [NCBI Bookshelf ID: NBK563295]. https://www.ncbi.nlm.nih.gov/books/NBK563295/

Reyna, M. A., Amorim, E., Sameni, R., Weigle, J., Elola, A., Bahrami Rad, A., Seyedi, S., Kwon, H., Zheng, W.-L., Ghassemi, M. M., van Putten, M. J. A. M., Hofmeijer, J., Gaspard, N., Sivaraju, A., Herman, S. T., Lee, J. W., Westover, M. B., & Clifford, G. D. (2023). Predicting Neurological Recovery from Coma After Cardiac Arrest: The George B. Moody PhysioNet Challenge 2023. *Computing in Cardiology*, *50*, 1-4. https://doi.org/10.22489/cinc.2023.019

Rossetti, A. O., Rabinstein, A. A., & Oddo, M. (2016). Neurological Prognostication of Outcome in Patients in Coma After Cardiac Arrest. *The Lancet Neurology*. https://doi.org/10.1016/s1474-4422(16)00015-6

Rudin, C. (2019). Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead. *Nature Machine Intelligence*. https://doi.org/10.1038/s42256-019-0048-x

Sabeti, M., Katebi, S., & Boostani, R. (2009). Entropy and Complexity Measures for EEG Signal Classification of Schizophrenic and Control Participants. *Artificial Intelligence in Medicine*. https://doi.org/10.1016/j.artmed.2009.03.003

Saeidi, M., Karwowski, W., Farahani, F. V., & Fiok, K. (2021). Neural Decoding of EEG Signals with Machine Learning: A Systematic Review. *Brain Sciences*. https://doi.org/10.3390/brainsci11111525

Sandroni, C., Cariou, A., Cavallaro, F., & Cronberg, T. (2014). Prognostication in Comatose Survivors of Cardiac Arrest: An Advisory Statement from the European Resuscitation Council and the European Society of Intensive Care Medicine. *Resuscitation*. https://doi.org/10.1016/j.resuscitation.2014.08.011

Sanei, S., & Chambers, J. A. (2007). *EEG Signal Processing*. Wiley. https://doi.org/10.1002/9780470511923

Schröer, C., Kruse, F., & Gómez, J. M. (2021). A Systematic Literature Review on Applying CRISP-DM Process Model. *Procedia Computer Science*. https://doi.org/10.1016/j.procs.2021.01.199

Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). Green AI. *Communications of the ACM*. https://doi.org/10.1145/3381831

Shannon, C. E. (1949). Communication in the Presence of Noise. *Proceedings of the IRE*, *37*(1), 10-21. https://doi.org/10.1109/JRPROC.1949.232969

Varoquaux, G., & Cheplygina, V. (2022). Machine Learning for Medical Imaging: Methodological Failures and Recommendations for the Future. *npj Digital Medicine*. https://doi.org/10.1038/s41746-022-00592-y

Welch, P. D. (1967). The Use of Fast Fourier Transform for the Estimation of Power Spectra: A Method Based on Time Averaging Over Short, Modified Periodograms. *IEEE Transactions on Audio and Electroacoustics*, *15*(2), 70-73. https://doi.org/10.1109/TAU.1967.1161901

Westhall, E., Rosén, I., Rossetti, A. O., van Rootselaar, A.-F., Wesenberg Kjaer, T., Friberg, H., Horn, J., Nielsen, N., Ullén, S., & Cronberg, T. (2015). Interrater Variability of EEG Interpretation in Comatose Cardiac Arrest Patients. *Clinical Neurophysiology*, *126*(12), 2397-2404. https://doi.org/10.1016/j.clinph.2015.03.017